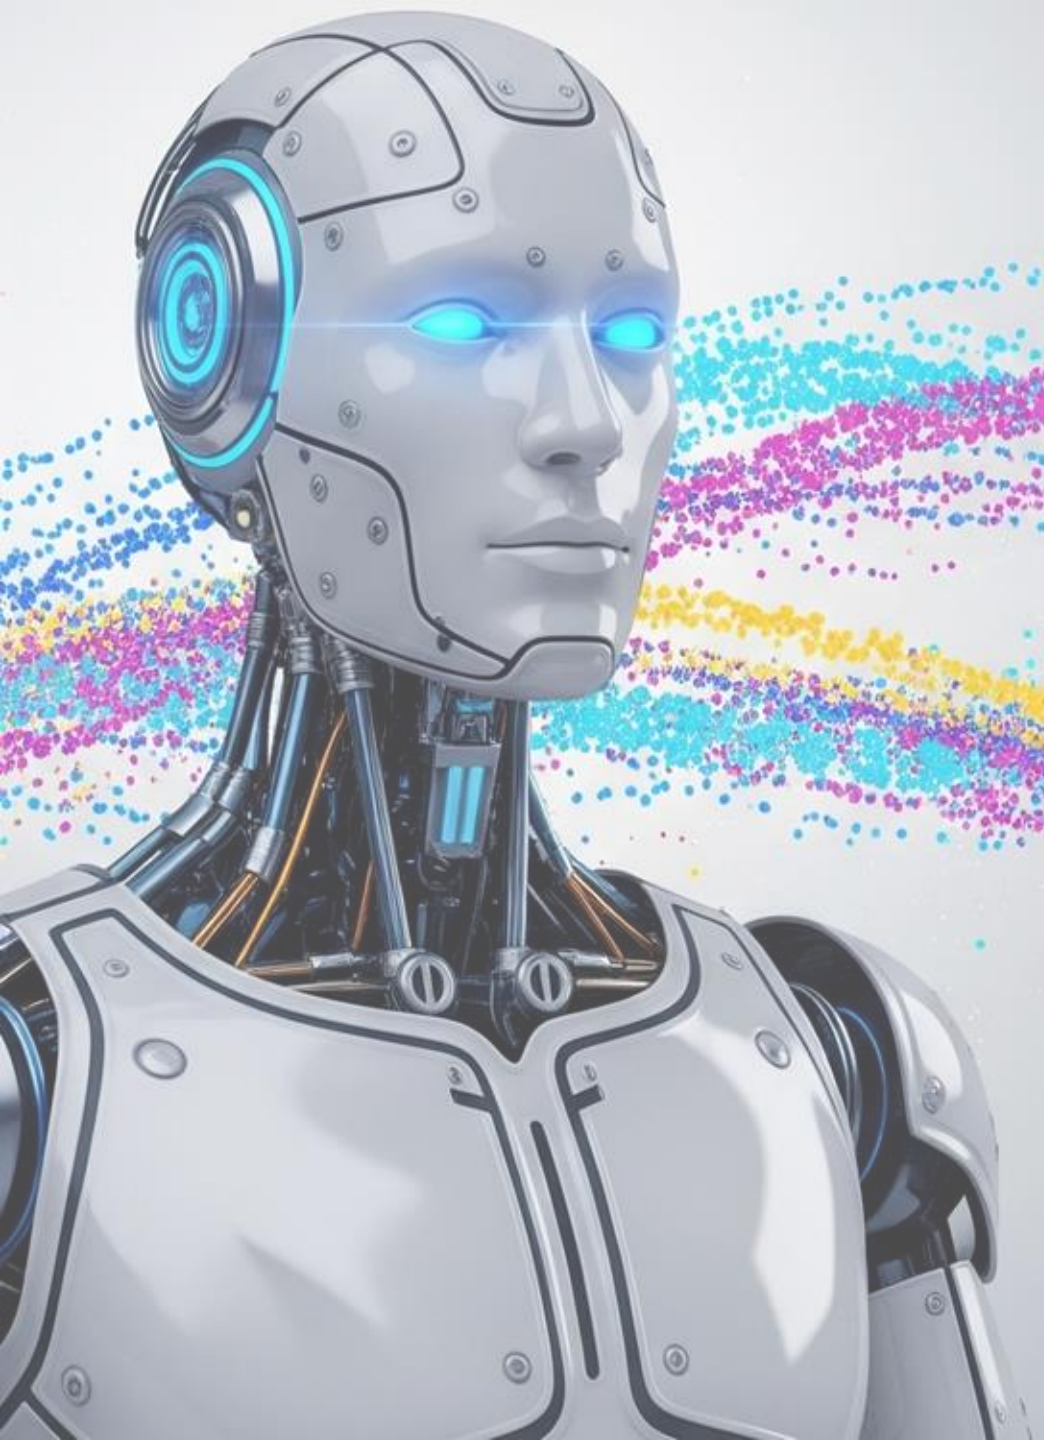


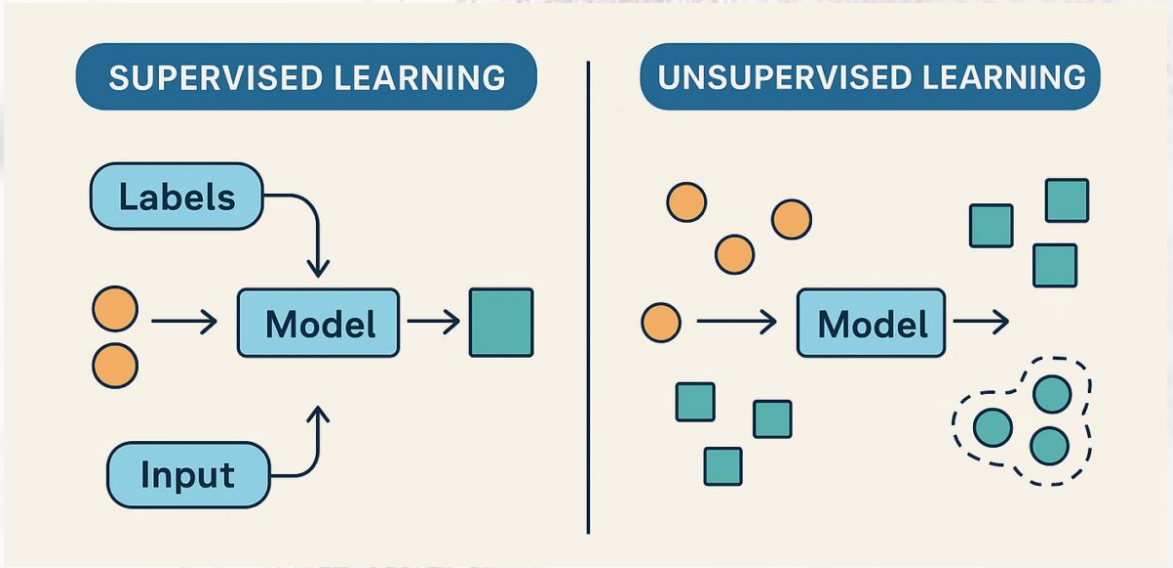
Chương 3: Học không giám sát

Ph.D. Nguyen Thi Khanh Tien

tiennntk@ut.edu.vn

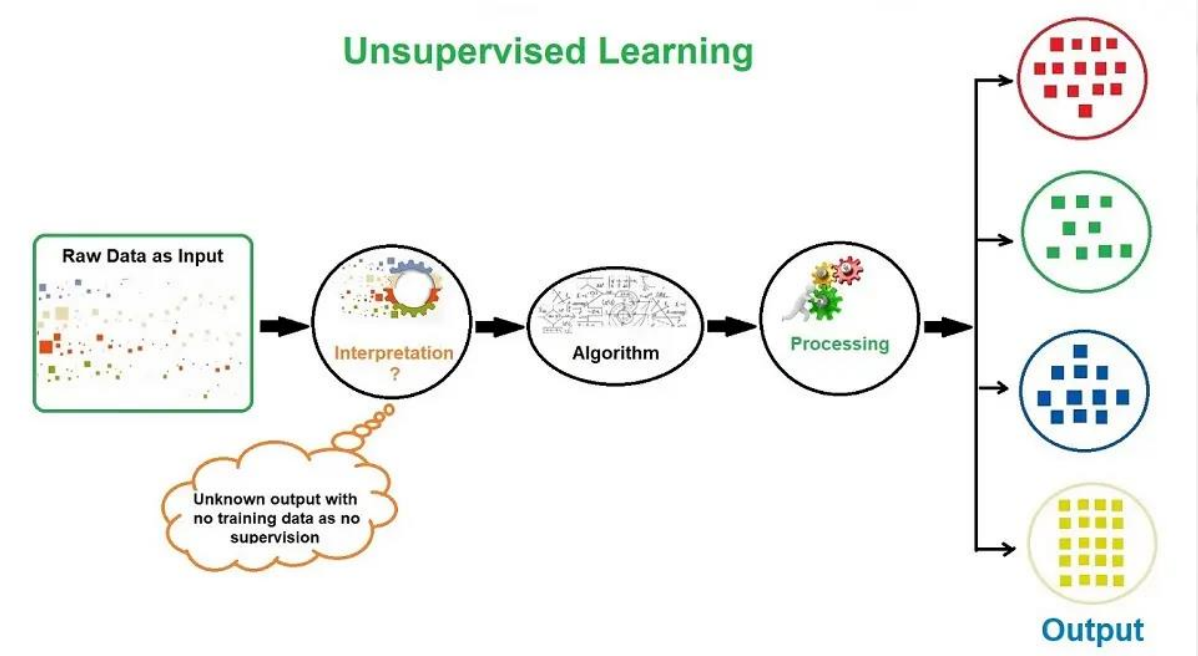
Giới thiệu về học tập không giám sát

Học không giám sát là một kỹ thuật học máy trong đó thuật toán học các mẫu và cấu trúc trong dữ liệu mà không cần hướng dẫn hoặc nhãn rõ ràng. Không giống như học có giám sát, yêu cầu dữ liệu được dán nhãn để huấn luyện mô hình, học không giám sát tập trung vào việc khám phá những hiểu biết sâu sắc và mối quan hệ ẩn bên trong chính dữ liệu đó.



Đặc điểm chính của học tập không giám sát

- **Không có nhãn:** Thuật toán không được cung cấp các biến hoặc lớp mục tiêu được xác định trước.
- **Khám phá mẫu:** Mục tiêu là xác định các mẫu, cụm hoặc điểm bất thường trong dữ liệu.
- **Phân tích khám phá:** Học không giám sát thường được sử dụng để phân tích dữ liệu khám phá nhằm hiểu rõ hơn về cấu trúc cơ bản.



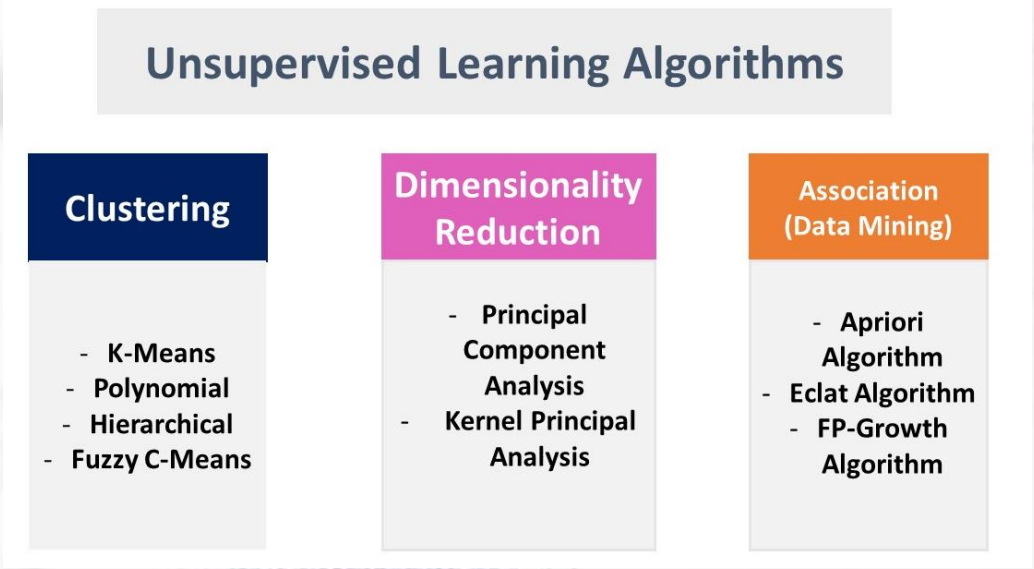
Ứng dụng học tập không giám sát

- **Phân khúc khách hàng:** Phân nhóm khách hàng dựa trên hành vi hoặc nhân khẩu học của họ.
- **Phân tích hình ảnh và video:** Xác định các đối tượng, cảnh hoặc điểm bất thường trong dữ liệu hình ảnh.
- **Phát hiện gian lận:** Phát hiện các mô hình bất thường trong giao dịch tài chính.
- **Hệ thống đề xuất:** Đề xuất các mục hoặc nội dung dựa trên sở thích của người dùng.
- **Tin sinh học:** Phân tích các mẫu biểu hiện gen hoặc cấu trúc protein.

Giới thiệu về học tập không giám sát

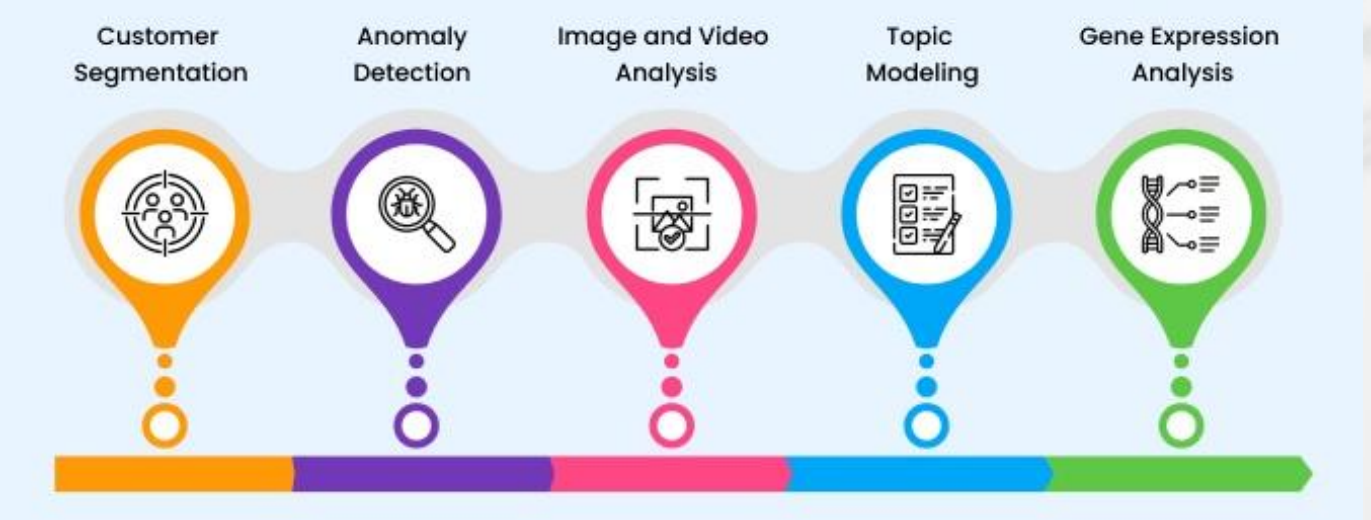
Các kỹ thuật học tập không giám sát phổ biến

- **Phân cụm:** Nhóm các điểm dữ liệu tương tự lại với nhau.
  - Ví dụ: K-means, phân cụm theo cấp bậc, DBSCAN
- **Giảm kích thước:** Giảm số lượng tính năng trong khi vẫn giữ được thông tin cần thiết.
  - Ví dụ: Phân tích thành phần chính (PCA), t-SNE
- **Phát hiện bất thường:** Xác định các điểm dữ liệu bất thường khác với quy chuẩn.
  - Ví dụ: Rừng cách ly, SVM một lớp
- **Khai thác quy tắc kết hợp:** Khám phá mối quan hệ giữa các mục trong tập dữ liệu.
  - Ví dụ: Thuật toán Apriori



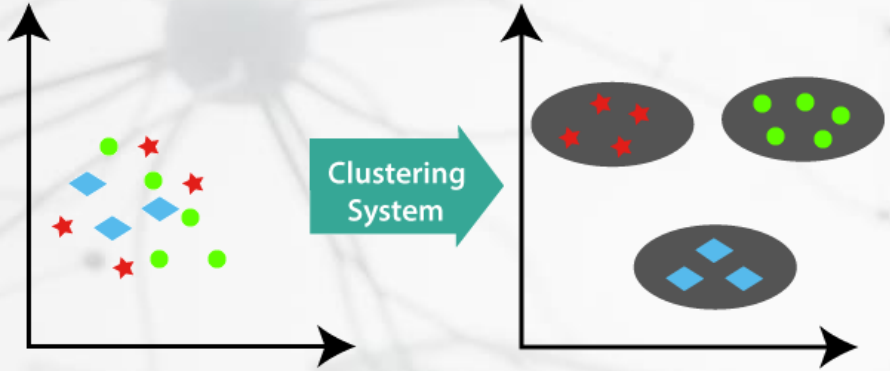
Những thách thức và cân nhắc

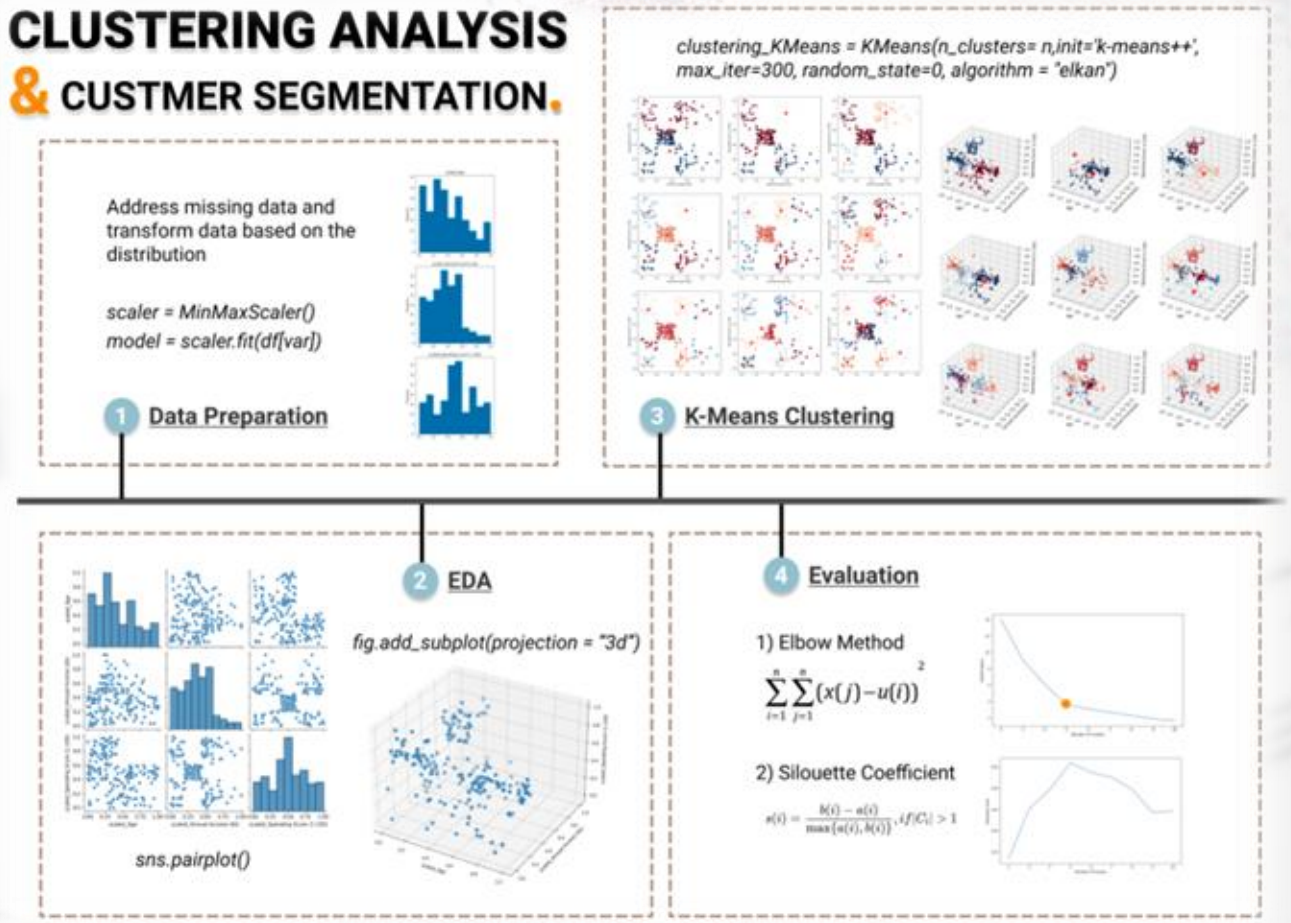
- **Đánh giá:** Việc đánh giá chất lượng của kết quả học tập không giám sát có thể gặp khó khăn do thiếu cơ sở thực tế.
- **Diễn giải:** Việc hiểu các mẫu được phát hiện bởi thuật toán không giám sát có thể yêu cầu chuyên môn về miền.
- **Khả năng mở rộng:** Một số thuật toán không được giám sát có thể gặp khó khăn với các tập dữ liệu lớn.



Giới thiệu về phân cụm

Phân cụm là một kỹ thuật máy học được sử dụng để nhóm các điểm dữ liệu tương tự lại với nhau. Đây là một nhiệm vụ học tập không giám sát cơ bản trong đó thuật toán xác định các mẫu hoặc cấu trúc tự nhiên trong dữ liệu mà không cần gắn nhãn trước.

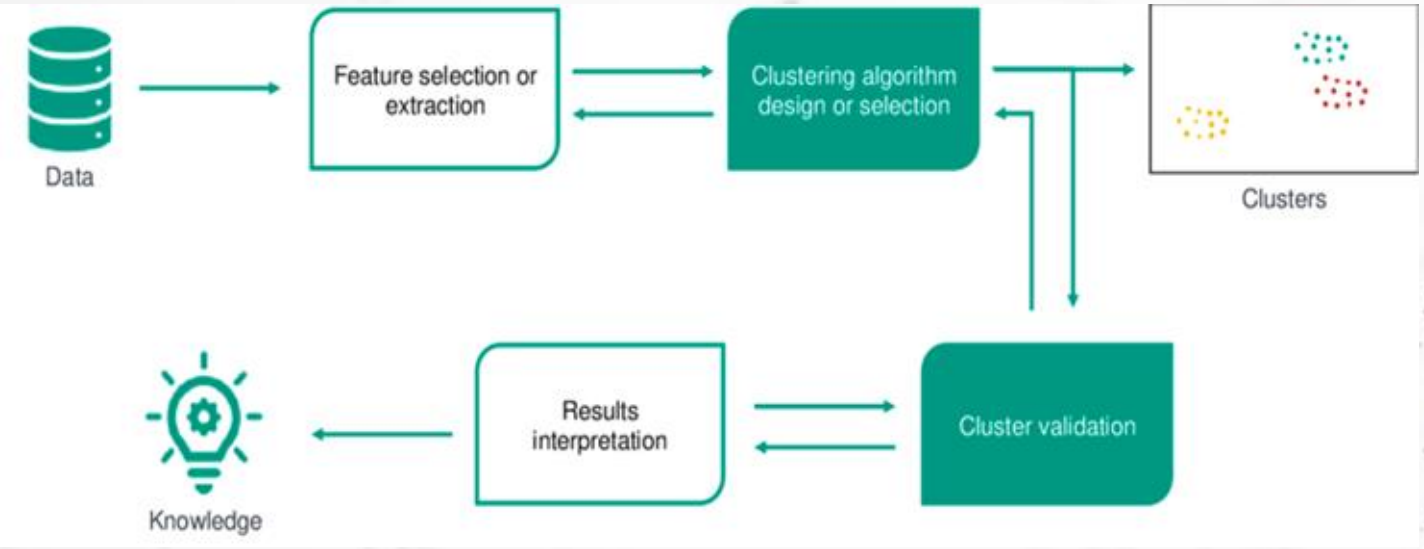




Ứng dụng phân cụm

- Phân khúc khách hàng: Phân nhóm khách hàng dựa trên nhân khẩu học, hành vi mua hàng hoặc sở thích của họ. - Phân đoạn hình ảnh: Chia hình ảnh thành các vùng riêng biệt dựa trên màu sắc, kết cấu hoặc hình dạng.
- Phát hiện bất thường: Xác định các điểm dữ liệu bất thường sai lệch so với định mức.
- Phân tích mạng xã hội: Khám phá các cộng đồng hoặc nhóm trong mạng.
- Tin sinh học: Phân tích các mẫu biểu hiện gen hoặc cấu trúc protein.

Đường dẫn phân cụm



1. Chuẩn bị dữ liệu

- **Thu thập** dữ liệu liên quan.
- Dữ liệu **Làm sạch**: Loại bỏ nhiễu, giá trị ngoại lệ và giá trị bị thiếu.
- Các tính năng của **Kỹ sư** giúp phân cụm tốt hơn.
- **Bình thường hóa** hoặc **chuẩn hóa** các tính năng thành một phạm vi chung.

2. Tính khoảng cách

- **Chọn** thước đo khoảng cách (ví dụ: Euclidean, Manhattan, Cosine, Hamming).
- **Tính** khoảng cách giữa tất cả các điểm dữ liệu.

3. Hình thành cụm

- **Khởi tạo** cụm: Chọn k và chọn ngẫu nhiên k trung tâm ban đầu.
- **Gán** điểm dữ liệu cho các trung tâm gần nhất.
- **Cập nhật** tâm cụm dựa trên các điểm được chỉ định.

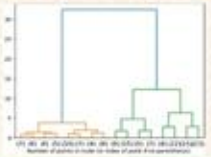
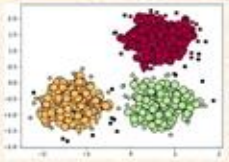
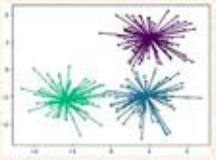
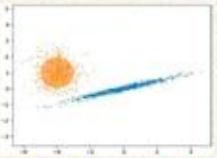
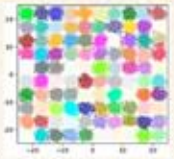
4. Lặp lại và sàng lọc

- **Lặp lại** phép gán và cập nhật cho đến khi hội tụ.
- **Hội tụ:** Dừng khi các nhiệm vụ đã ổn định hoặc các lần lặp lại đạt đến giới hạn.

5. Đánh giá

- **Đánh giá** chất lượng cụm (ví dụ: hình bóng, Calinski-Harabasz, Davies-Bouldin).
- **Trực quan hóa** các cụm để hiểu.

Các loại thuật toán phân cụm

Type of Clustering Algorithm	Visual Overview	Description	Algorithm(s)
Centroid-based		Cluster points based on proximity to centroid	KMeans KMeans++ KMedoids
Connectivity-based		Cluster points based on proximity between clusters	Hierarchical Clustering (Agglomerative and Divisive)
Density-based		Cluster points based on their density instead of proximity	DBSCAN OPTICS HDBSCAN
Graph-based		Cluster points based on graph distance	Affinitiy Propagation Spectral Clustering
Distribution-based		Cluster points based on their likelihood of belonging to the same distribution.	Gaussian Mixture Models
Compression-based		Transform data to a lower dimensional space and then perform clustering	BIRCH

Tổng quan về các phương pháp phân cụm trong scikit-learn.
→https://scikit-learn.org/1.5/modules/clustering.html

Ví dụ trong Scikit-learn.
So sánh các thuật toán phân cụm khác nhau trên bộ dữ liệu đồ chơi →https://scikit-learn.org/0.18/auto_examples/cluster/plot_cluster_comparison.html

Việc lựa chọn thuật toán phân cụm phù hợp phụ thuộc vào một số yếu tố, bao gồm:
- Đặc điểm dữ liệu. Hình dạng, kích thước và sự phân bố của dữ liệu.
- Số cụm mong muốn. Số lượng nhóm dự kiến hoặc đã biết.
- Tài nguyên tính toán. Sức mạnh tính toán có sẵn

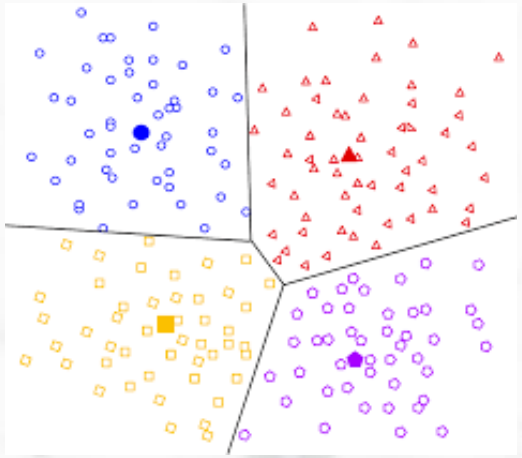
- Khả năng giải thích. Sự dễ hiểu và giải thích kết quả.

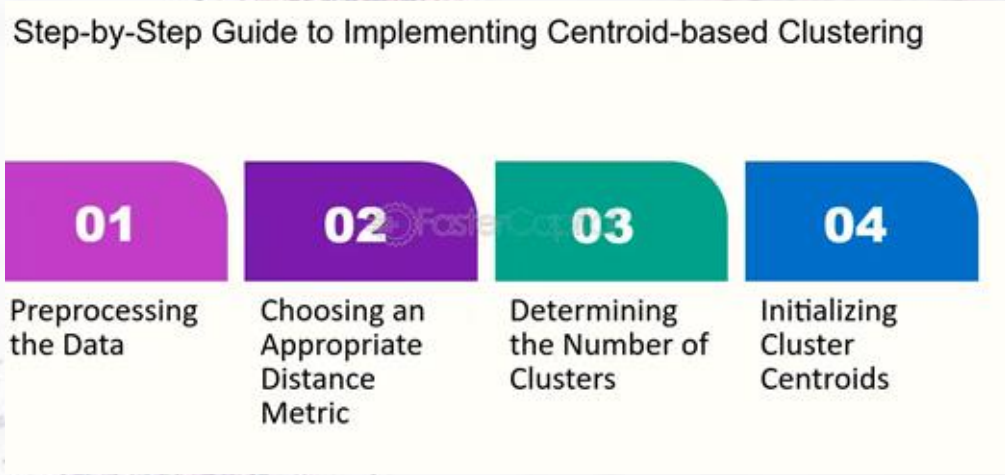
Phân cụm dựa trên Centroid

Phân cụm dựa trên trọng tâm là một phương pháp học không giám sát trong đó các điểm dữ liệu được nhóm lại dựa trên khoảng cách của chúng với tâm của mỗi cụm. Trọng tâm là điểm trung bình của tất cả các điểm dữ liệu trong một cụm.

Các thuật toán dựa trên Centroid phổ biến:

- Phân cụm K-mean -
Phân cụm K-medoids





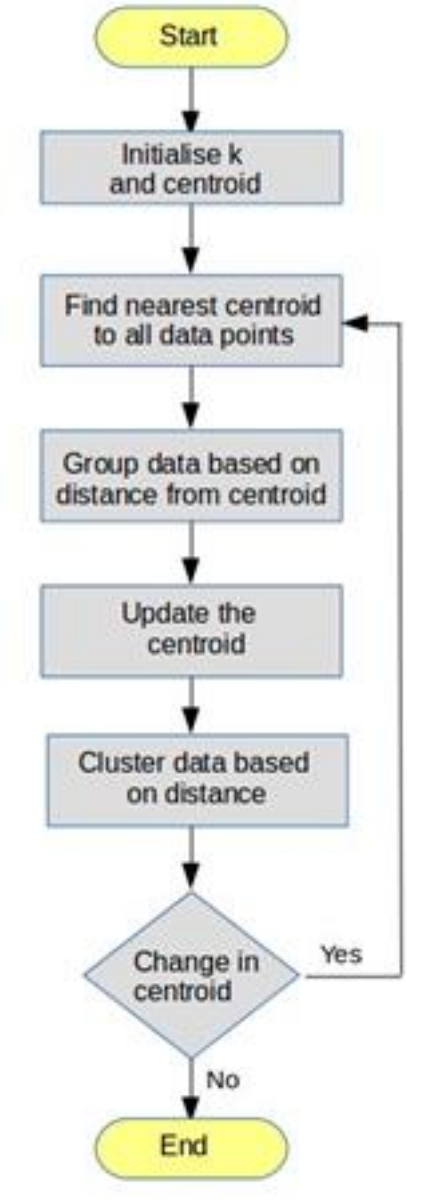
Những cân nhắc chính:

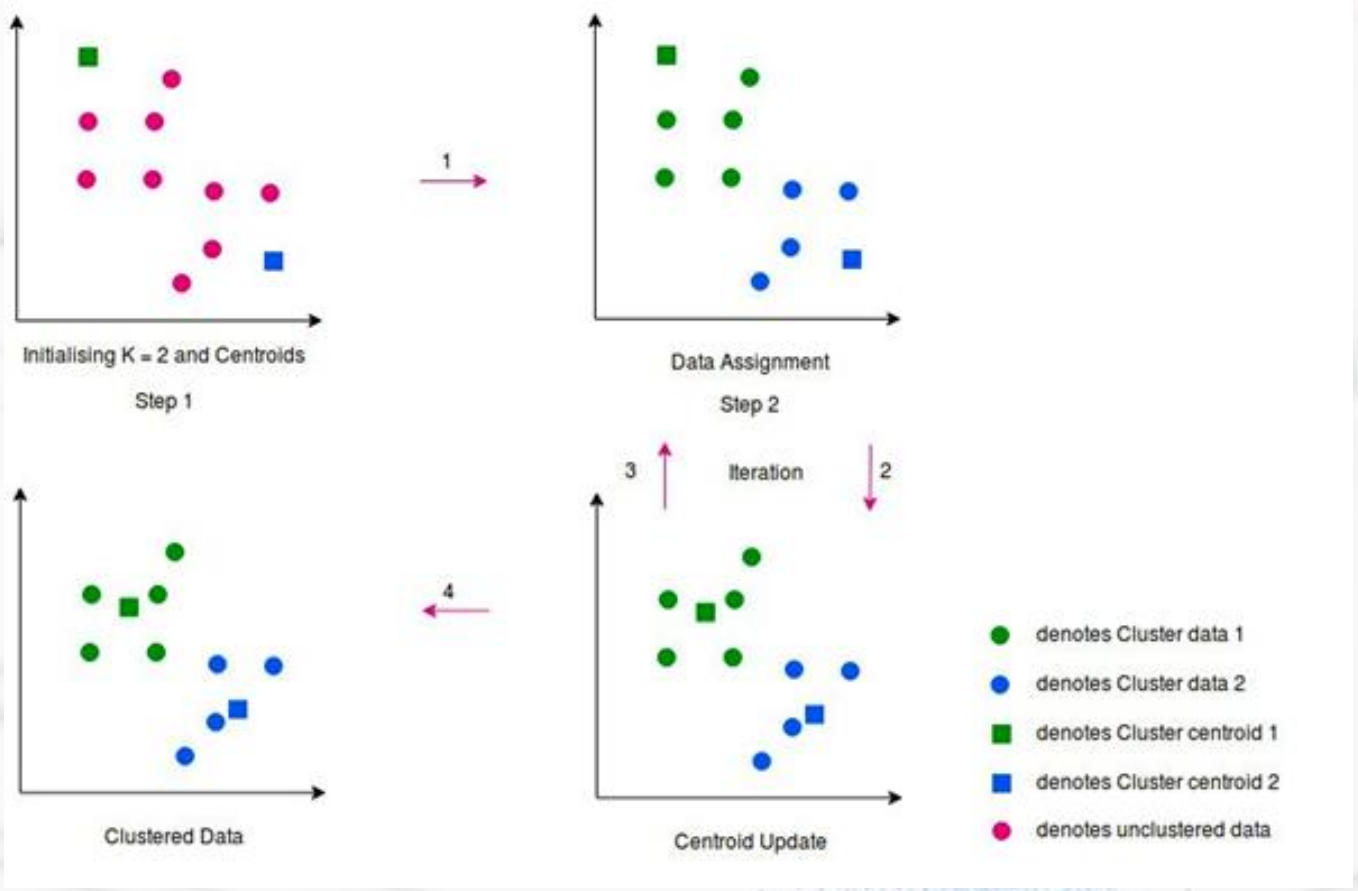
- *Việc chọn đúng giá trị k.* Số lượng cụm có thể ảnh hưởng đáng kể đến kết quả. Các kỹ thuật như phương pháp khuỷu tay hoặc hệ số hình bóng có thể giúp xác định k tối ưu. - *Xử lý các ngoại lệ.* Các ngoại lệ có thể ảnh hưởng đến trọng tâm và dẫn đến việc phân cụm không chính xác. Các kỹ thuật như phát hiện ngoại lệ hoặc phương tiện K- mạnh mẽ có thể được sử dụng để giải quyết vấn đề này.

- *Chia tỷ lệ các đối tượng.* Nếu các đối tượng có tỷ lệ khác nhau, điều quan trọng là phải chuẩn hóa hoặc tiêu chuẩn hóa chúng để ngăn các đối tượng có tỷ lệ lớn hơn chiếm ưu thế trong quá trình phân cụm.

Tính năng	K-nghĩa	K-medoid
Centroid/Medoid	Ý nghĩa của điểm dữ liệu	Điểm dữ liệu trong cụm
cập nhật	Tính toán lại nghĩa là	Trao đổi medoid
Nhạy cảm với các ngoại lệ	Nhạy cảm	Mạnh mẽ hơn
Hiệu quả	Nhanh hơn	Chậm hơn
Kiểu dữ liệu	Số	Có thể xử lý phân loại
Khi nào nên chọn cái nào	Nếu bạn có một tập dữ liệu lớn và cần nhanh chóng kết quả, K-nghĩa là một lựa chọn tốt.	Nếu bạn là quan tâm đến các giá trị ngoại lệ hoặc có dữ liệu phân loại, K-medoids là tốt hơn tùy chọn.

K-means Algorithm





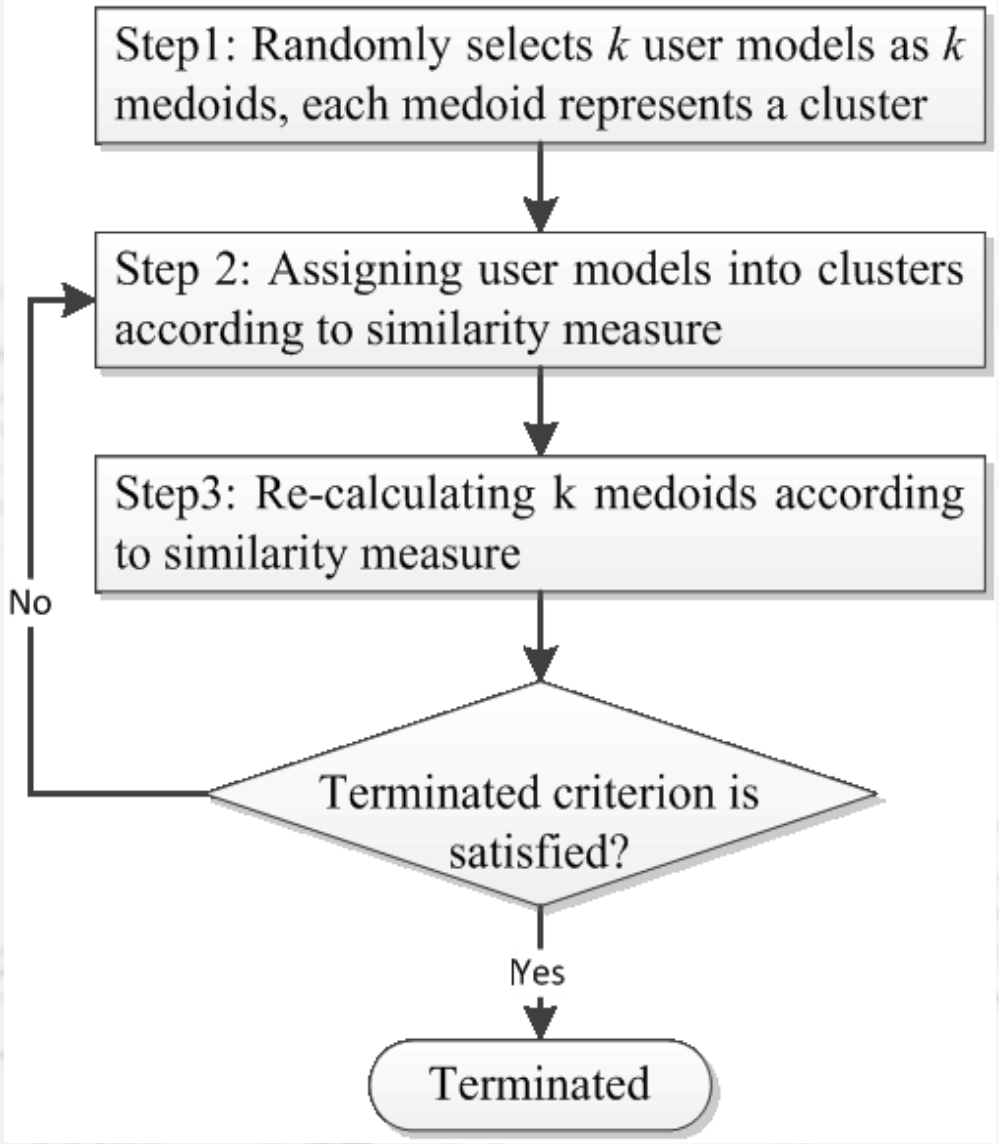
1. Khởi tạo k điểm, được gọi là ‘centroid’, ngẫu nhiên hoặc từ tập dữ liệu.

2. Bước gán dữ liệu – Nhóm tất cả các điểm dữ liệu riêng lẻ với trọng tâm gần nhất để tạo thành các cụm.

3. Bước cập nhật Centroid – Tính giá trị của centroid là giá trị trung bình của các mục thuộc mỗi cụm.

4. Lặp lại bước 2 và 3 cho đến khi giá trị trọng tâm không đổi giữa các lần lặp liên tiếp.

Thuật toán K-medoid



Khởi tạo:

- Chọn ngẫu nhiên k điểm dữ liệu làm medoids.

Anhiệm vụ:

- Gán từng điểm dữ liệu cho medoid gần nhất dựa trên thước đo khoảng cách (ví dụ: khoảng cách Euclide).

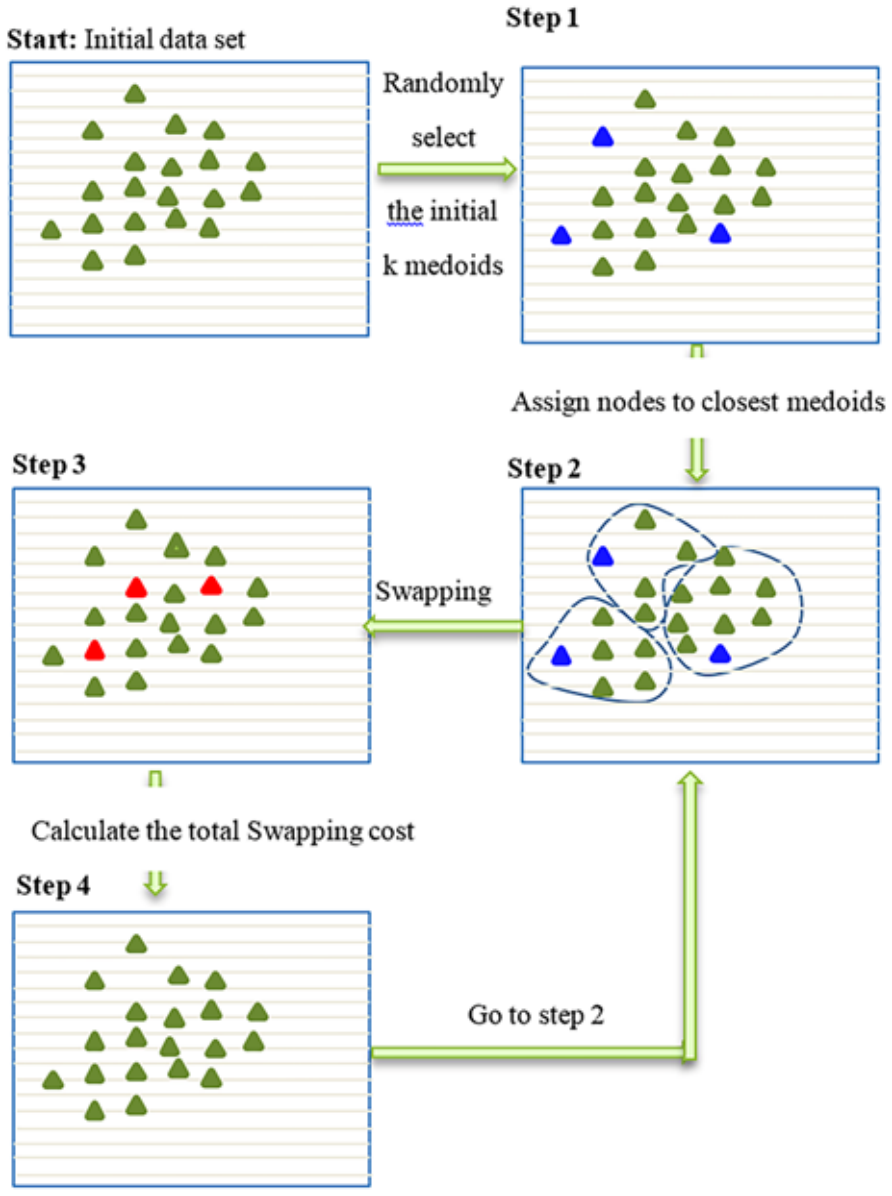
Cập nhật:

- Với mỗi medoid, hãy tính tổng khoảng cách tới tất cả các điểm được gán cho nó.
- Hoán đổi medoid hiện tại với một điểm không phải medoid nếu việc hoán đổi dẫn đến giảm tổng khoảng cách.
- Lặp lại quá trình này cho tất cả các medoids.

Lặp lại:

- Lặp lại bước 2 và 3 cho đến khi không còn thay đổi nào trong phép gán medoid hoặc đạt đến số lần lặp xác định.

Thuật toán K-medoid



Ví dụ trong Scikit-learn:

→

https://codinginfinite.com/k-medoids-clustering-algorithm-with-number-example/#google_vignette

Phân cụm dựa trên mật độ

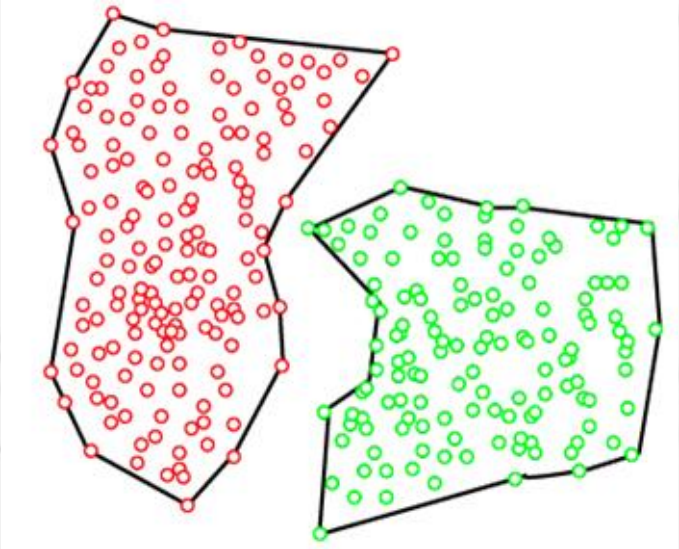
Phân cụm dựa trên mật độ là một loại thuật toán học không giám sát nhóm các điểm dữ liệu dựa trên mật độ của chúng. Nó xác định các cụm là các vùng có mật độ cao được phân tách bằng các vùng có mật độ thấp. Cách tiếp cận này hữu ích cho việc khám phá các cụm có hình dạng tùy ý, không giống như các phương pháp dựa trên centroid như K-mean giả sử các cụm có dạng hình cầu.

Thuật toán dựa trên mật độ phổ biến:

- DBSCAN (Phân cụm không gian dựa trên mật độ của các ứng dụng có nhiễu) - OPTICS (Sắp xếp các điểm để xác định cấu trúc phân cụm)

Những cân nhắc chính:

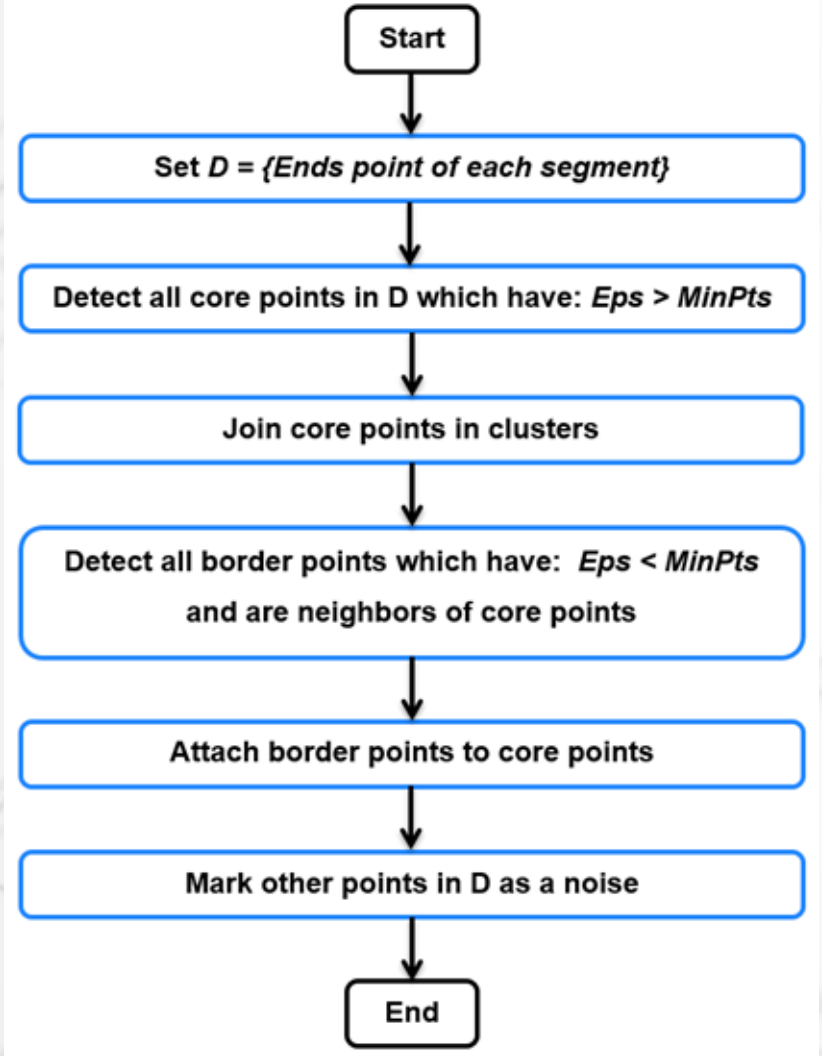
- *Lựa chọn tham số.* Việc chọn các giá trị thích hợp cho ε và MinPts trong DBSCAN có thể tác động đáng kể đến kết quả phân cụm. - *Xử lý tiếng ồn.* Các phương pháp dựa trên mật độ có thể xử lý tiếng ồn một cách hiệu quả bằng cách xác định các điểm không thuộc bất kỳ cụm nào. - *Khả năng mở rộng.* Đối với các tập dữ liệu lớn, các kỹ thuật như lập chỉ mục không gian có thể cải thiện hiệu quả của các thuật toán dựa trên mật độ.

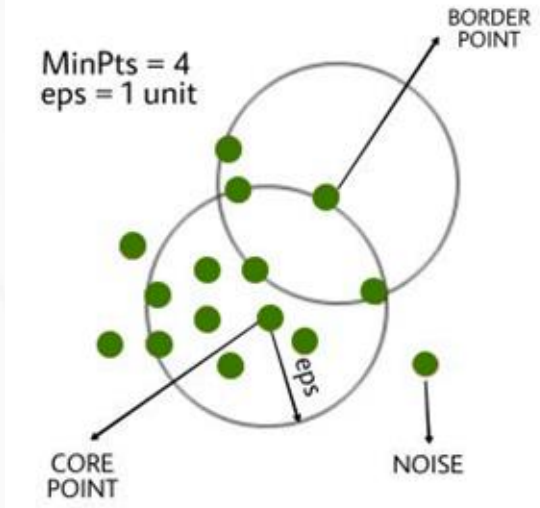


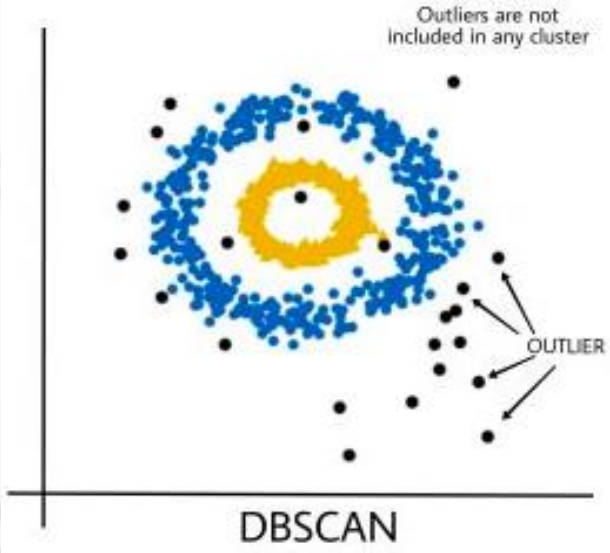
Tính năng	DBSCAN	OPTICS
Kiểu phân cụm	Phân cụm trực tiếp	Phân cụm theo cấp bậc
Thông số	εvà MinPts	MinPts
Cấu trúc cụm	phẳng	Phân cấp
Độ nhạy tham số	Nhạy cảm	Ít hơnhạy cảm
Xử lý tiếng ồn	rõ ràng	ngầm
Khi nào nên chọn cái nào	Nếu bạn có ý kiến rõ ràng hoặc hiểu biết về ngưỡng mật độ trong dữ liệu của bạn và cần một bộ phẳng của cụm	Nếu bạn muốn trình bày theo thứ bậc của các cụm và không chắc chắn về mật độ tối ưu

Thuật toán DBSCAN

DBSCAN là thuật toán phân cụm dựa trên mật độ, nhóm các điểm dữ liệu dựa trên mật độ của chúng. Nó xác định các cụm là các vùng có mật độ cao được phân tách bằng regions of low density.







Mã giả cho thuật toán phân cụm DBSCAN

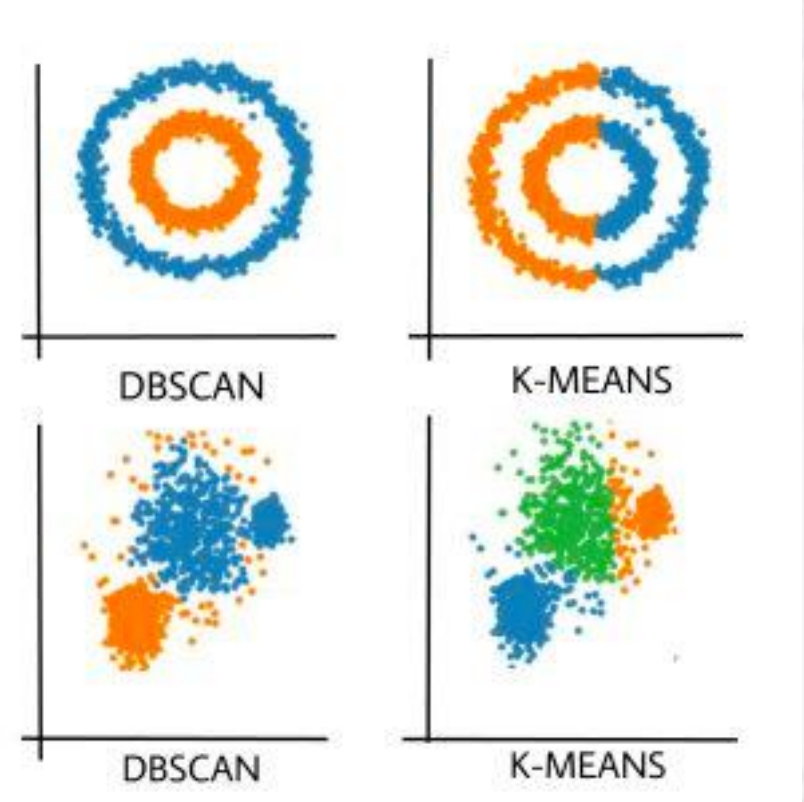
```
DBSCAN(dataset, eps, MinPts){
# cluster index
C = 1
for each unvisited point p in dataset {
          mark p as visited
          # find neighbors
          Neighbors N = find the neighboring points of p

          if |N|>=MinPts:
              N = N U N'
              if p' is not a member of any cluster:
                  add p' to cluster C
}
```

Trong Scikit_learn,

Sự khác biệt giữa DBSCAN và K-Means

tính năng	K-nghĩa là	DBSCAN
Nguyên tắc phân cụm	Dựa trên Centroid	Dựa trên mật độ
Hình dạng cụm	Giả sử hình cầu	Tay cầmhình dạng tùy ý
Số của cụm	Đã sửa (k)	Được xác định tự động
Nhạy cảm với các ngoại lệ	Nhạy cảm	Mạnh mẽ

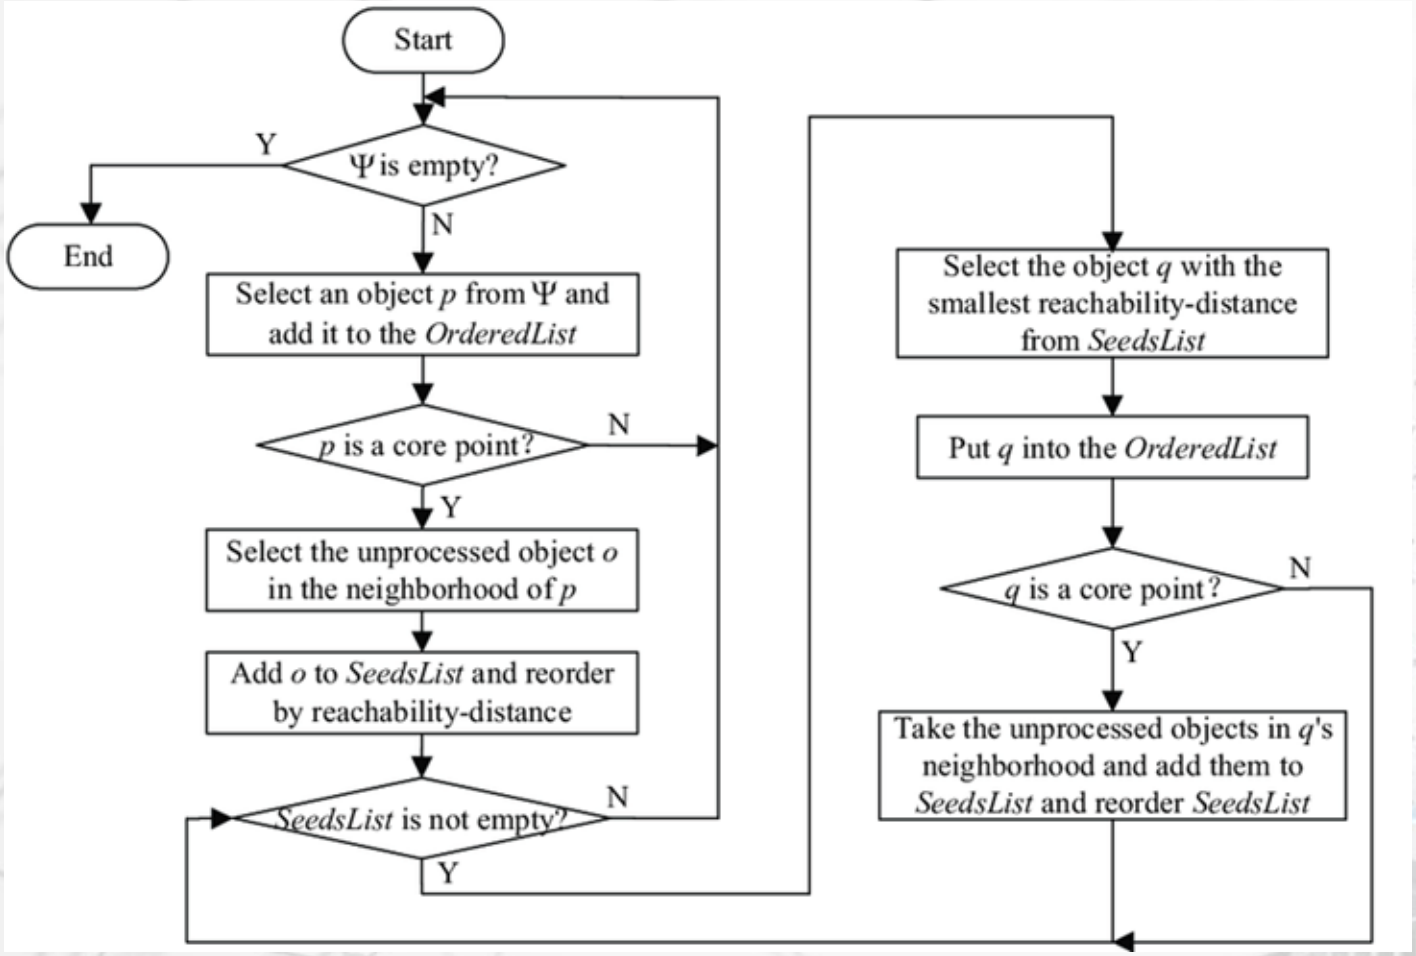


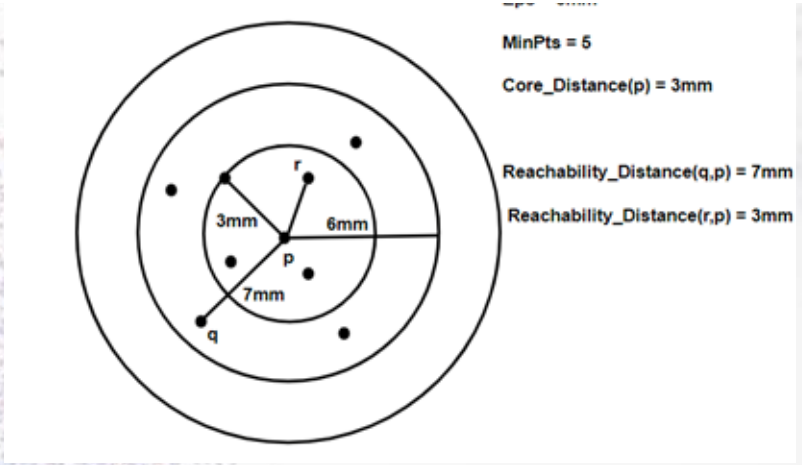
Khi nào nên chọn cái nào:

- **K-means:** Nếu bạn hiểu rõ về số lượng cụm và tin rằng chúng gần như có dạng hình cầu thì K-means là một lựa chọn tốt.
- **DBSCAN:** Nếu bạn không chắc chắn về số lượng cụm hoặc nếu chúng có hình dạng không đều, DBSCAN là một lựa chọn tốt hơn.

Quang học

OPTICS là thuật toán phân cụm dựa trên mật độ mở rộng DBSCAN để tạo ra sự biểu diễn phân cấp của các cụm. Nó đặc biệt hữu ích khi mật độ điểm dữ liệu thay đổi đáng kể.





Tính toán khoảng cách lõi. Đối với mỗi điểm dữ liệu, hãy tính khoảng cách lõi của nó, là bán kính tối thiểu sao cho điểm đó có ít nhất lân cận MinPts trong bán kính đó.

Tính toán khoảng cách tiếp cận. Đối với mỗi điểm dữ liệu, hãy tính khoảng cách có thể tiếp cận của nó từ một điểm khác. Khoảng cách có thể tiếp cận là khoảng cách tối đa của lõi của điểm đầu tiên và khoảng cách Euclide giữa hai điểm.

Điểm đặt hàng. Sắp xếp các điểm dữ liệu dựa trên khoảng cách có thể tiếp cận của chúng.

Trích xuất cụm. Trích xuất các cụm từ các điểm được sắp xếp dựa trên ngưỡng mật độ mong muốn.

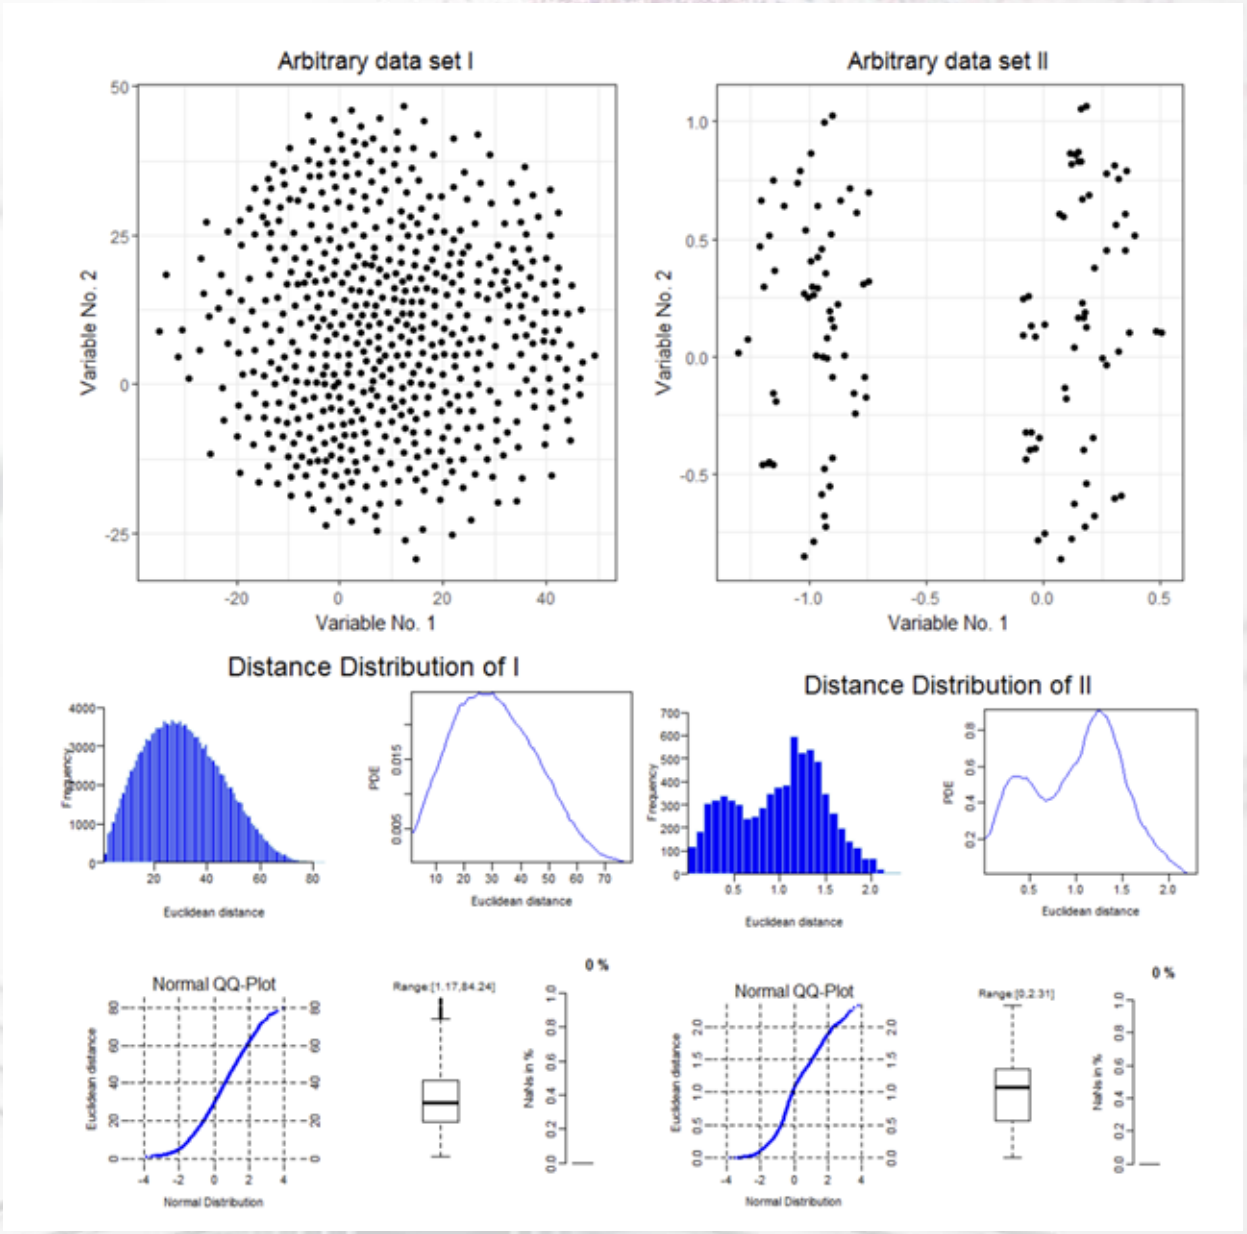
Phân cụm dựa trên phân phối

Phân cụm dựa trên phân phối là một loại thuật toán học không giám sát giả định các điểm dữ liệu được tạo từ phân phối xác suất cơ bản. Nó nhằm mục đích nhóm các điểm dữ liệu có khả năng được lấy từ cùng một bản phân phối.

Những cân nhắc chính:

- *Chọn số lượng linh kiện*. Số lượng thành phần Gaussian trong GMM có thể tác động đáng kể đến kết quả phân cụm. Các kỹ thuật như Tiêu chí Thông tin Bayesian (BIC) hoặc Tiêu chí Thông tin Akaike (AIC) có thể giúp xác định con số tối ưu.

- *Khởi tạo*n. Việc khởi tạo các tham số GMM có thể ảnh hưởng đến độ hội tụ và kết quả cuối cùng. Có thể sử dụng các kỹ thuật như khởi tạo ngẫu nhiên hoặc phân cụm k-mean.
- *Tối ưu cục bộ*. GMM có thể hội tụ về mức tối ưu cục bộ, dẫn đến các giải pháp dưới mức tối ưu. Nhiều lần khởi động lại hoặc các kỹ thuật tối ưu hóa khác có thể giúp giảm thiểu điều này.



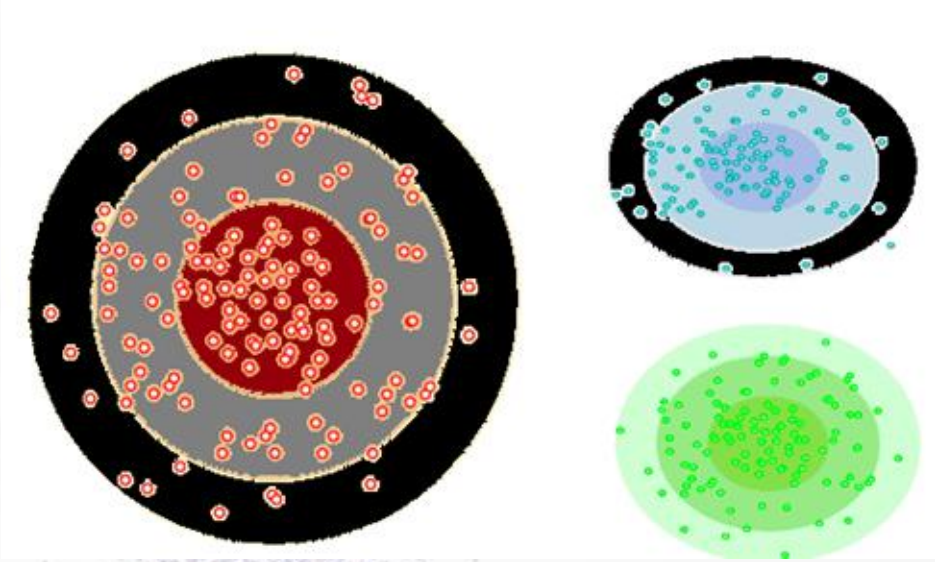
Phân cụm dựa trên phân phối

Thuật toán dựa trên phân phối khóa:

- Mô hình hỗn hợp Gaussian (GMM)
- Mô hình Markov ẩn (HMM)
- Mô hình hỗn hợp

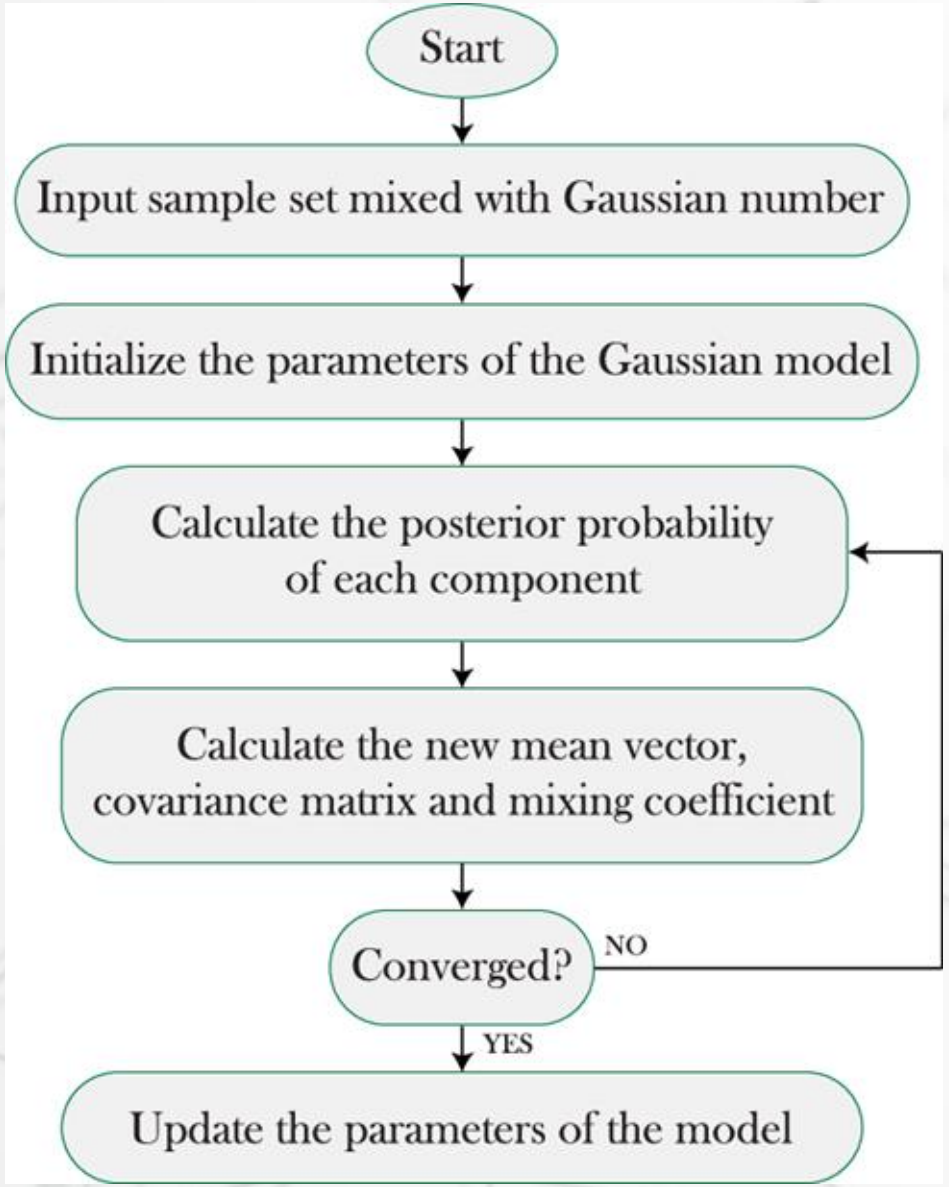
Việc lựa chọn thuật toán dựa trên phân phối phụ thuộc vào điều kiện cụ thể vấn đề và đặc điểm dữ liệu:

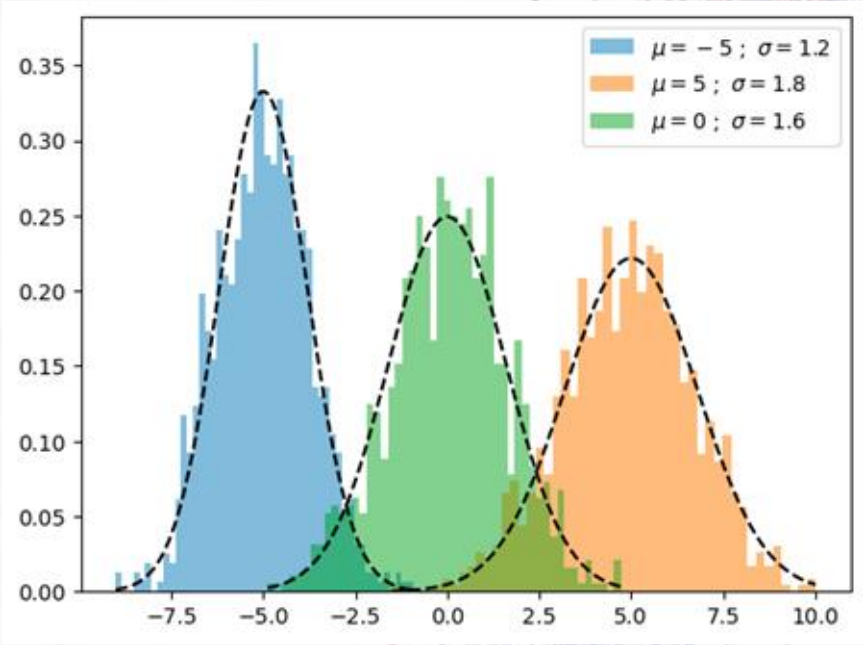
- GMM phù hợp cho việc phân cụm dữ liệu thành các nhóm chồng chéo.
- HMM rất hữu ích cho việc mô hình hóa dữ liệu tuần tự với các trạng thái ẩn.
- Mô hình hỗn hợp cung cấp tính linh hoạt để mô hình hóa các phân phối dữ liệu khác nhau, nhưng yêu cầu lựa chọn cẩn thận phân phối thích hợp



Tính năng	GMMs	HMMs	Hỗn hợpMô hình
Giả định dữ liệu	Hỗn hợp các phân bố Gaussian	Quá trình Markovới các trạng thái ẩn	Hỗn hợp của bất kỳ phân phối tham số nào
Mục tiêu	Xác định các thành phần Gaussian	Suy ra ẩn trạng thái và xác suất chuyển tiếp	Xác định các phân phối và tham số cơ bản
Phương pháp	Thuật toán tối đa hóa kỳ vọng (EM)	Thuật toán Baum-Welch	Thuật toán EM(hoặc khácỹ thuật tối ưu hóa)

Mô hình hỗn hợp Gaussian (GMM)





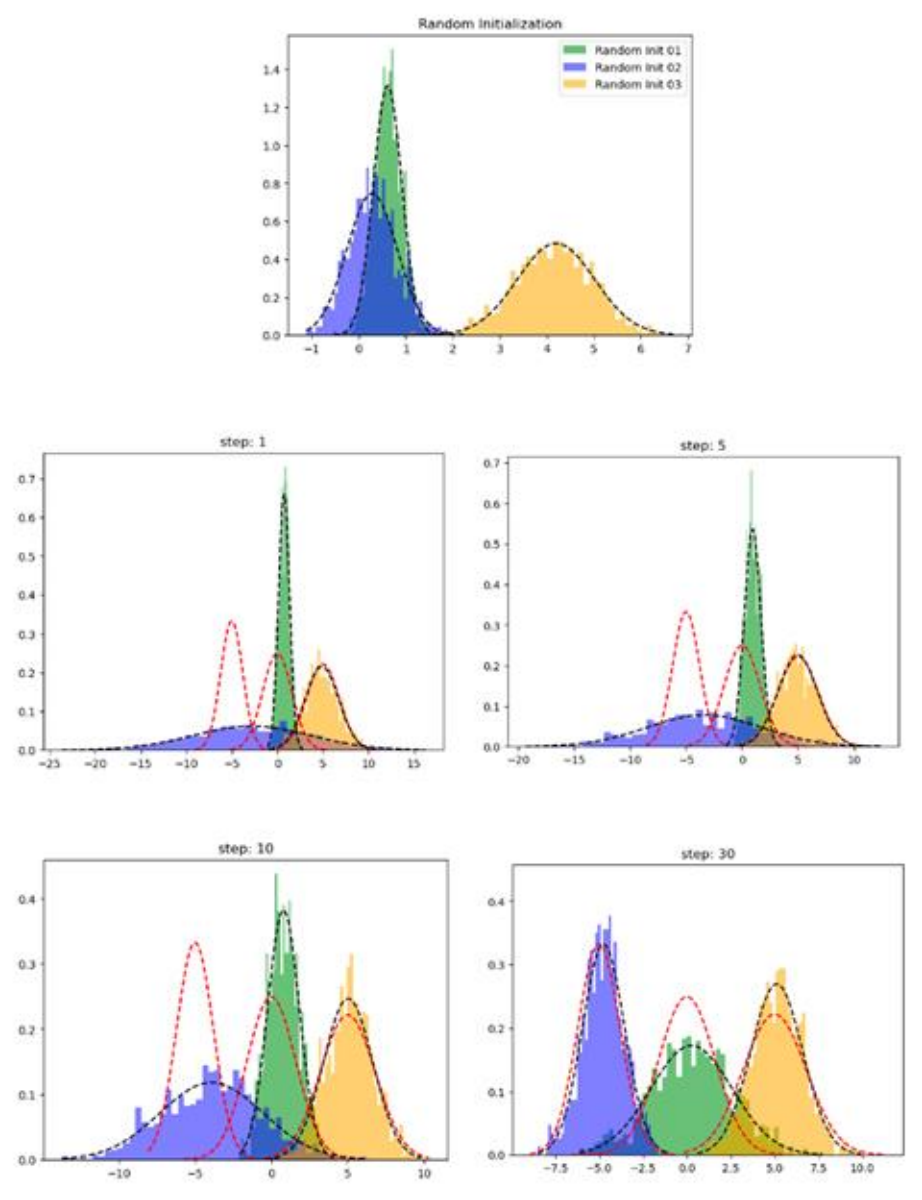
Khởi tạo. Khởi tạo ngẫu nhiên các tham số của từng thành phần Gaussian (phương tiện, hiệp phương sai và trọng số).

Bước kỳ vọng (Bước E). Tính xác suất của từng điểm dữ liệu thuộc từng thành phần Gaussian dựa trên các tham số hiện tại. Điều này được thực hiện bằng định lý Bayes.

Bước tối đa hóa (bước M). Cập nhật các tham số của từng thành phần Gaussian để tối đa hóa khả năng của dữ liệu được thực hiện các nhiệm vụ hiện tại. Điều này liên quan đến việc tính toán lại giá trị trung bình, hiệp phương sai và trọng số bằng cách sử dụng các xác suất được tính toán.

Lặp lại. Lặp lại bước E và bước M cho đến khi hội tụ (các thông số không thay đổi đáng kể).

Mô hình hỗn hợp Gaussian (GMM)



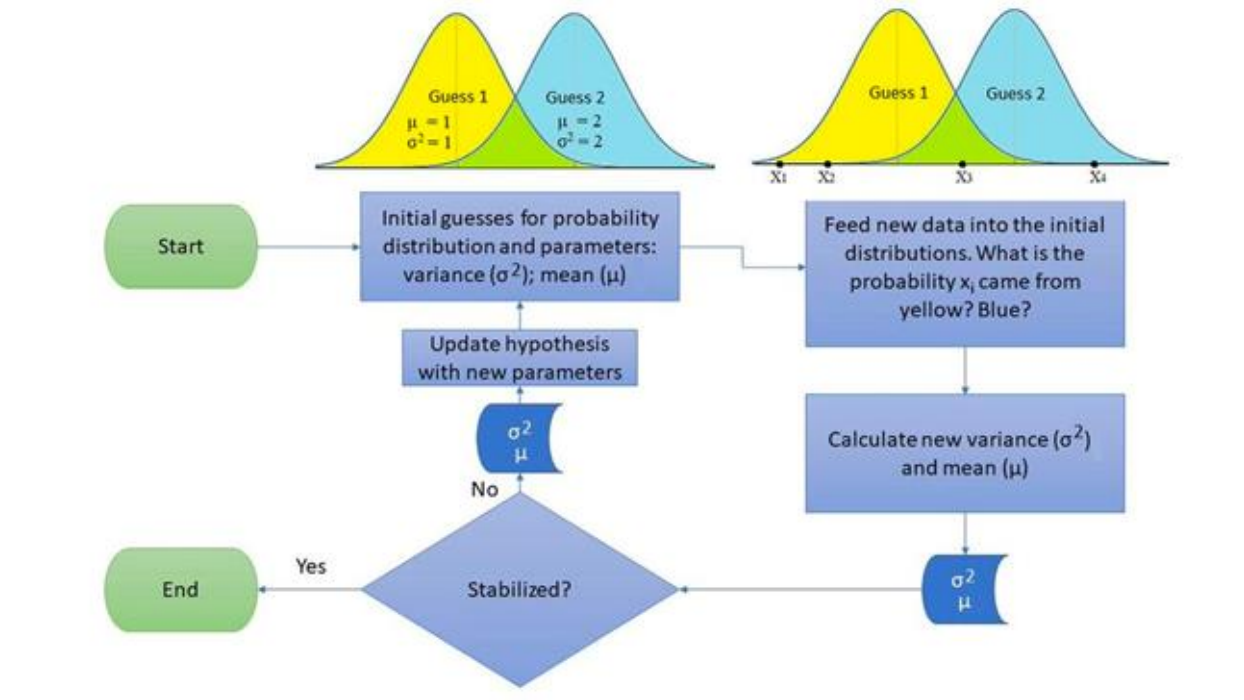
Ví dụ về học scikit:

1)https://scikit-learn.org/1.5/modules/mixture.html#gaussian-mixture

2)https://scikit-learn.org/1.5/auto_examples/mixture/plot_gmm_covariances.html#sphx-glr-auto-examples-mixture-plot-gmm-covariances-py

Thuật toán tối đa hóa kỳ vọng (EM)

Expectation-Maximization (EM) is an iterative algorithm commonly used for maximum likelihood estimation in statistical models, especially when there is missing data or latent variables. It's a powerful tool for clustering and other unsupervised learning tasks.



Khởi tạo. Khởi tạo ngẫu nhiên các tham số của mô hình.

Bước kỳ vọng (Bước E). Với các giá trị tham số hiện tại, hãy tính giá trị mong đợi của dữ liệu bị thiếu hoặc các biến tiềm ẩn. Bước này liên quan đến việc sử dụng mô hình hiện tại để ước tính phân bố xác suất của dữ liệu bị thiếu hoặc các biến tiềm ẩn.

Bước tối đa hóa (bước M). Với các giá trị mong đợi từ bước E, hãy cập nhật các tham số mô hình để tối đa hóa khả năng xảy ra của dữ liệu được quan sát. Điều này liên quan đến việc tối ưu hóa các tham số mô hình đối với dữ liệu hoàn chỉnh (được quan sát và dự kiến).

Lặp lại. Lặp lại bước E và bước M cho đến khi hội tụ (các thông số không thay đổi đáng kể).

Phương pháp phân cụm theo cấp bậc

Phân cụm theo cấp bậc là một loại thuật toán học không giám sát tạo ra một hệ thống phân cấp các cụm, bắt đầu từ các điểm dữ liệu riêng lẻ và hợp nhất chúng thành các cụm lớn hơn cho đến khi tất cả các điểm dữ liệu nằm trong một cụm duy nhất.

Các kiểu phân cụm theo cấp bậc:

1. Tích tụ (Phương pháp tiếp cận từ dưới lên):

- **Bước ban đầu:** Bắt đầu bằng cách coi mỗi điểm dữ liệu là một cụm riêng biệt. Vì vậy, nếu có N điểm dữ liệu, bạn bắt đầu với N cụm. -**Quy trình phân cụm:**Trong mỗi bước, thuật toán sẽ gộp hai cụm gần nhau nhất cho đến khi tất cả các cụm được hợp nhất thành một cụm lớn chứa tất cả các điểm dữ liệu.
- **Dendrogram:** Kết quả có thể được biểu diễn dưới dạng cấu trúc dạng cây gọi là dendrogram, cho thấy sự sắp xếp của các cụm và khoảng cách giữa chúng.

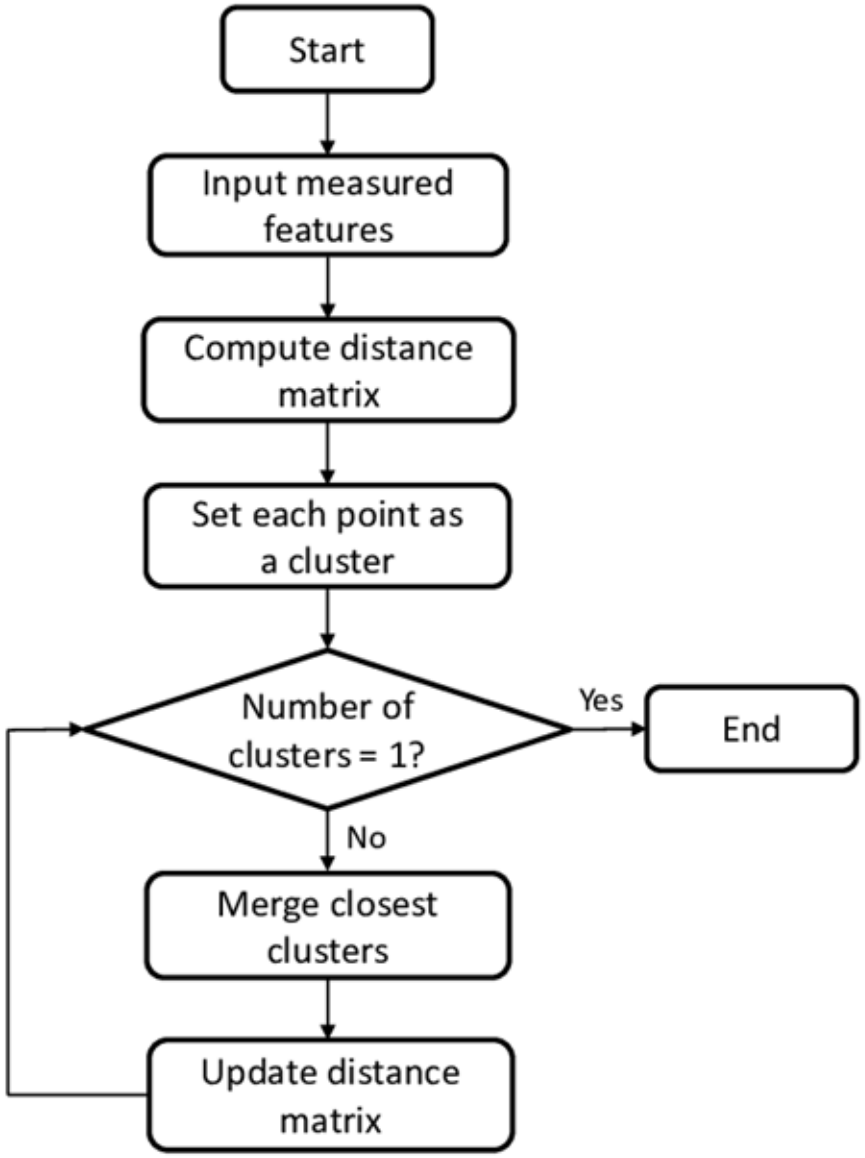
2. Chia rẽ (Phương pháp tiếp cận từ trên xuống):

- **Bước ban đầu:** Bắt đầu với tất cả các điểm dữ liệu trong một cụm.
- **Quy trình phân cụm:** Ở mỗi bước, thuật toán sẽ chia cụm cho đến khi mỗi cụm chỉ chứa một điểm dữ liệu. - **Phân tách từ trên xuống:** Điều này ít phổ biến hơn so với phân cụm kết tụ và chuyên sâu hơn về mặt tính toán.



Feature	Agglomerative Hierarchical Clustering	Divisive Hierarchical Clustering
Approach	Bottom-up	Top-down
Efficiency	Less efficient for large datasets	More efficient for large datasets
Sensitivity to Noise	More sensitive to noise	Less sensitive to noise
Cluster Shape	Can handle clusters of arbitrary shapes	Can handle clusters of arbitrary shapes

Phương pháp phân cụm theo cấp bậc



Phân cụm theo cấp bậc sử dụng thước đo khoảng cách/độ tương tự để tạo các cụm mới. Các bước để phân cụm kết tụ có thể được tóm tắt như sau:

- Bước 1: Tính ma trận độ gần bằng cách sử dụng thước đo khoảng cách cụ thể
- Bước 2: Mỗi điểm dữ liệu được gán cho một cụm
- Bước 3: Hợp nhất các cụm dựa trên thước đo về độ giống nhau giữa các cụm
- Bước 4: Cập nhật ma trận khoảng cách
- Bước 5: Lặp lại Bước 3 và Bước 4 cho đến khi chỉ còn lại một cụm duy nhất

Việc lựa chọn phương pháp phân cụm theo cấp bậc phụ thuộc vào nhiều yếu tố khác nhau, bao gồm:

- **Kích thước tập dữ liệu.** Đối với các tập dữ liệu lớn, phương pháp chia có thể hiệu quả hơn.
- **Mức nhiễu.**Đối với các tập dữ liệu nhiễu, phương pháp phân chia có thể mạnh mẽ hơn.
- **Hình dạng cụm.** Cả hai phương pháp đều có thể xử lý các cụm có hình dạng tùy ý, nhưng việc lựa chọn tiêu chí liên kết hoặc phân tách có thể ảnh hưởng đến kết quả.
- **Số lượng cụm mong muốn.** Các phương pháp tổng hợp linh hoạt hơn trong việc xác định số lượng cụm bằng cách cắt chương trình dendro ở các cấp độ khác nhau.

Phương pháp phân cụm theo cấp bậc

Sự tương đồng giữa các cụm

Câu hỏi chính trong phân cụm theo cấp bậc là làm thế nào để tính khoảng cách giữa các cụm và cập nhật ma trận lân cận. Có nhiều cách tiếp cận khác nhau được sử dụng để trả lời câu hỏi đó. Mỗi cách tiếp cận đều có ưu điểm và nhược điểm. 1. Liên kết đơn (Khoảng cách tối thiểu) có thể xử lý các cụm không hình cầu, nhạy cảm với các ngoại lệ, nhưng có xu hướng tạo ra các cụm dạng chuỗi, nhạy cảm với nhiễu. 2. Liên kết hoàn chỉnh (Khoảng cách tối đa). Mạnh mẽ trước tiếng ồn và các ngoại lệ, nhưng có xu hướng tạo ra các cụm hình cầu chặt chẽ, có thể nhạy cảm với các cụm nhỏ. 3. Liên kết trung bình cân bằng độ nhạy của liên kết đơn và liên kết hoàn chỉnh, nhưng có thể tốn kém về mặt tính toán đối với các tập dữ liệu lớn.

4. Centroid-Linkage tương đối hiệu quả, có thể xử lý các cụm không hình cầu, nhưng nhạy cảm với các ngoại lệ, có thể tạo ra các cụm không cân bằng.

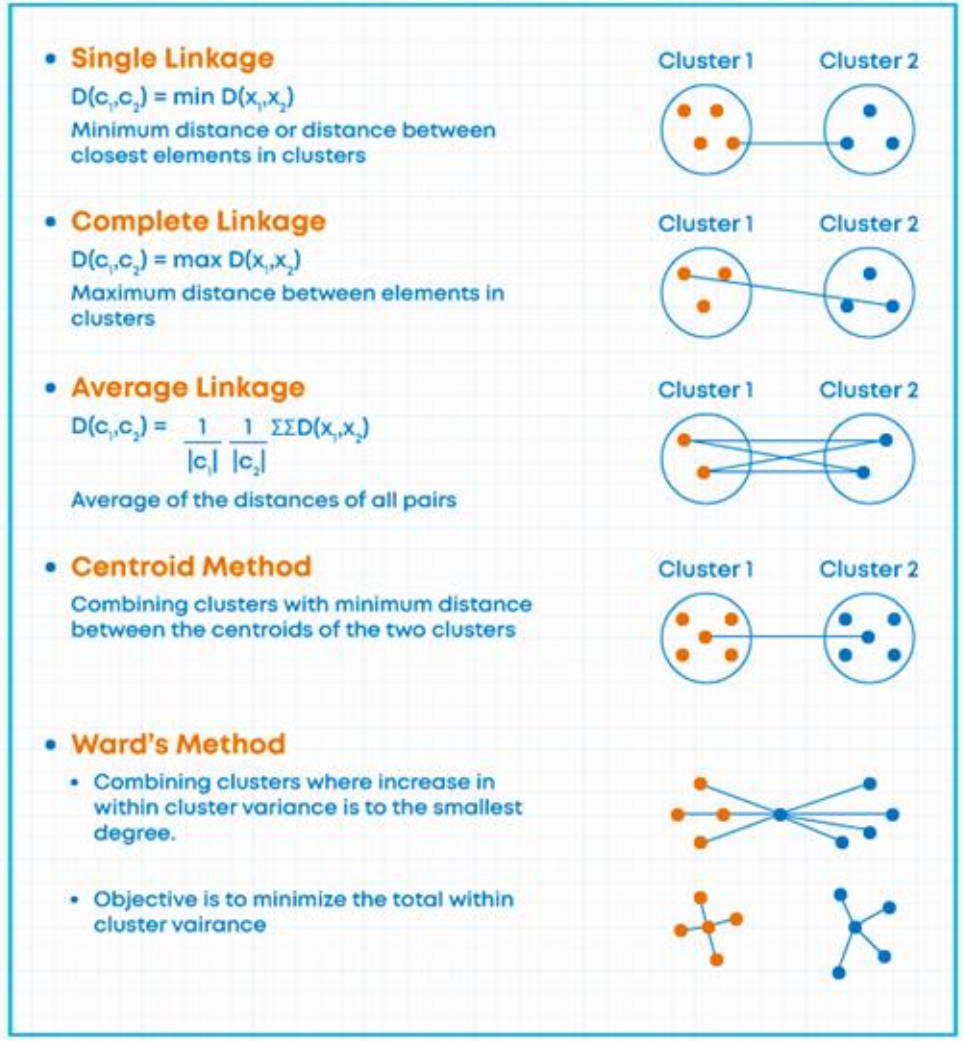
5. Ward's Linkage chịu được nhiễu và các ngoại lệ, có xu hướng tạo ra các cụm hình cầu nhỏ gọn, nhưng có thể nhạy cảm với các điều kiện ban đầu, có thể không xử lý tốt các cụm không hình cầu.

Chọn phương pháp phù hợp:

Việc lựa chọn phương pháp liên kết phụ thuộc vào đặc điểm cụ thể của tập dữ liệu và kết quả phân cụm mong muốn. Hãy xem xét các yếu tố sau: -Noise và Outliers: Nếu dữ liệu chứa nhiễu hoặc các ngoại lệ đáng kể, thì phương pháp liên kết hoàn chỉnh hoặc phương pháp của Ward có thể mạnh mẽ hơn.

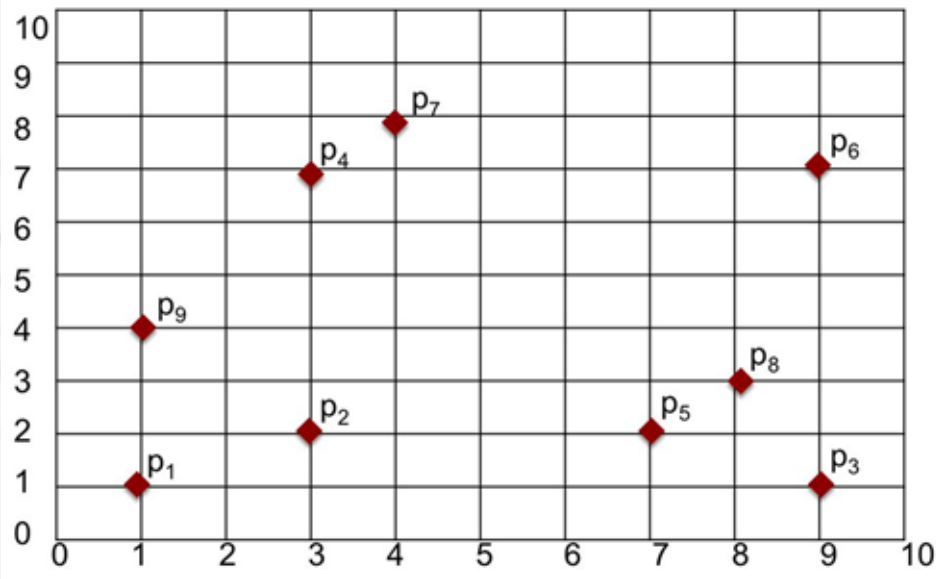
- Hình dạng cụm: Đối với các cụm không hình cầu, liên kết đơn hoặc liên kết trung bình có thể phù hợp hơn.
- Chi phí tính toán: Đối với các tập dữ liệu lớn, phương pháp centroid -linkage hoặc Ward có thể hiệu quả hơn.

Số liệu khoảng cách để phân cụm theo cấp bậc:

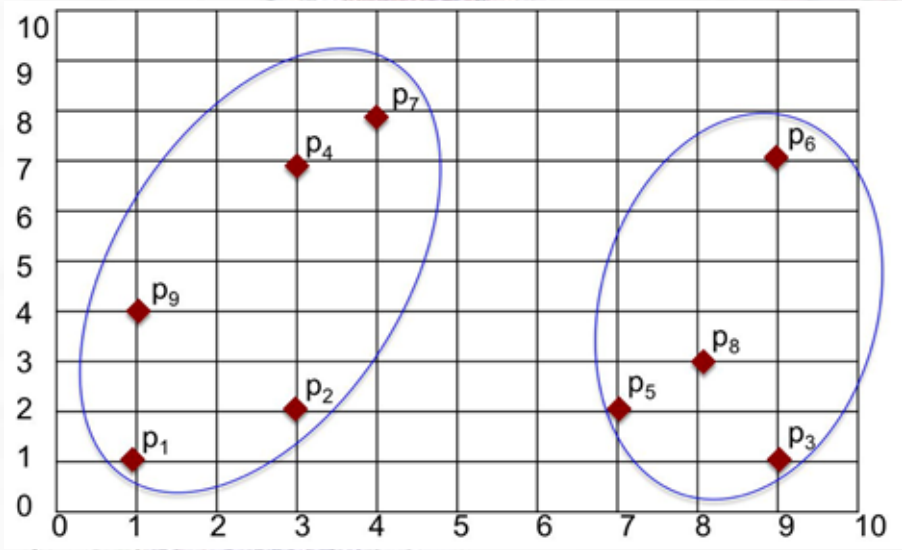


Phương pháp phân cụm theo cấp bậc

Thực hiện phân tích phân cụm trên tập dữ liệu hai chiều, chín điểm được cung cấp để xác định hai cụm riêng biệt



Point	x	y
p_1	1	1
p_2	3	2
p_3	9	1
p_4	3	7
p_5	7	2
p_6	9	7
p_7	4	8
p_8	8	3
p_9	1	4



Tính ma trận tiệm cận

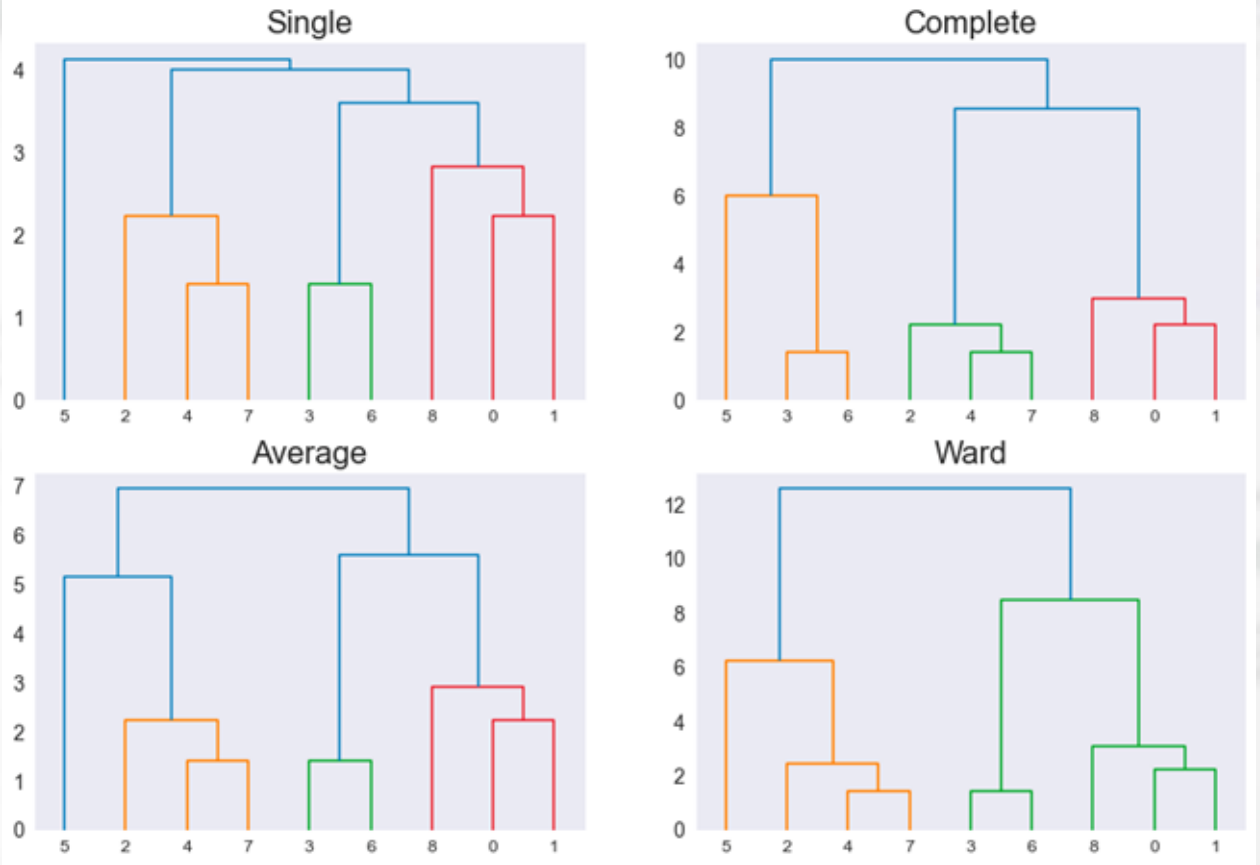
	p_1	p_2	p_3	...	p_n
p_1	$d(p_1,p_1)$	$d(p_1,p_2)$	$d(p_1,p_3)$	...	$d(p_1,p_n)$
p_2	$d(p_2,p_1)$	$d(p_2,p_2)$	$d(p_2,p_3)$	...	$d(p_2,p_n)$
p_3	$d(p_3,p_1)$	$d(p_3,p_2)$	$d(p_3,p_3)$	...	$d(p_3,p_n)$
...	...	...	...	...	...
p_n	$d(p_n,p_1)$	$d(p_n,p_2)$	$d(p_n,p_3)$	...	$d(p_n,p_n)$

Phương pháp phân cụm theo cấp bậc

```
from scipy.cluster.hierarchy import dendrogram, linkage

Z1 = linkage(X1, method='single', metric='euclidean')
Z2 = linkage(X1, method='complete', metric='euclidean')
Z3 = linkage(X1, method='average', metric='euclidean')
Z4 = linkage(X1, method='ward', metric='euclidean')
```

```
plt.figure(figsize=(15, 10))
plt.subplot(2,2,1), dendrogram(Z1), plt.title('Single')
plt.subplot(2,2,2), dendrogram(Z2), plt.title('Complete')
plt.subplot(2,2,3), dendrogram(Z3), plt.title('Average')
plt.subplot(2,2,4), dendrogram(Z4), plt.title('Ward')
plt.show()
```

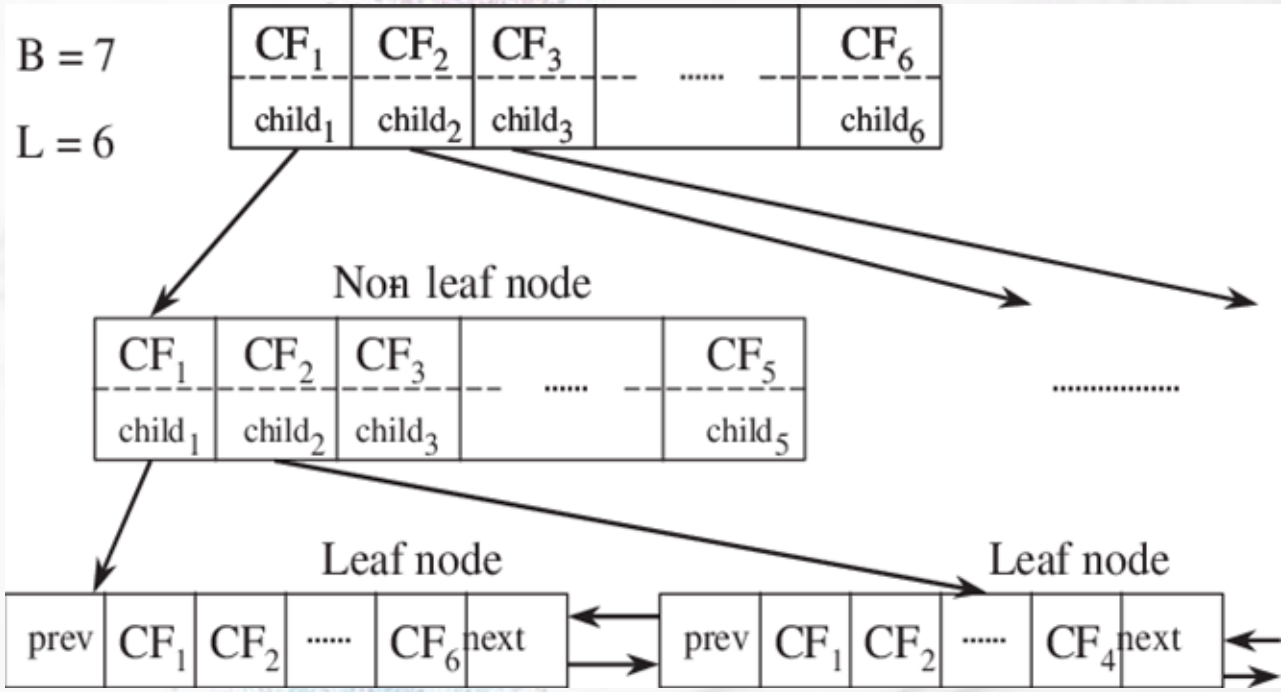


Thuật toán BIRCH

BIRCH (Giảm lặp và phân cụm cân bằng bằng cách sử dụng cấu trúc phân cấp) là một thuật toán phân cụm được thiết kế để xử lý hiệu quả các tập dữ liệu lớn. Nó đặc biệt hữu ích cho việc phân tích dữ liệu khám phá và tiền xử lý cho các thuật toán phân cụm khác.

Các khái niệm chính:

- **Tính năng phân cụm (CF):** CF là bản tóm tắt của một cụm. Nó chứa ba thuộc tính chính:
  - **Số điểm (N):** Số lượng điểm dữ liệu trong cụm.
  - **Tổng tuyến tính (LS):** Tổng của tất cả các điểm dữ liệu trong cụm.
  - **Tổng bình phương (SS):** Tổng giá trị bình phương của tất cả các điểm dữ liệu trong cụm.
- **Cây CF:** Cấu trúc dữ liệu dạng cây dùng để tổ chức các CF. Nó có hai loại nút:
  - **Các nút không có lá:** Các nút này có con và lưu trữ CF.
  - **Nút lá:** Các nút này lưu trữ CF và có thể có con trỏ tới các nút con.



Thuật toán BIRCH

BIRCH hoạt động như thế nào:

1. Quét cơ sở dữ liệu:

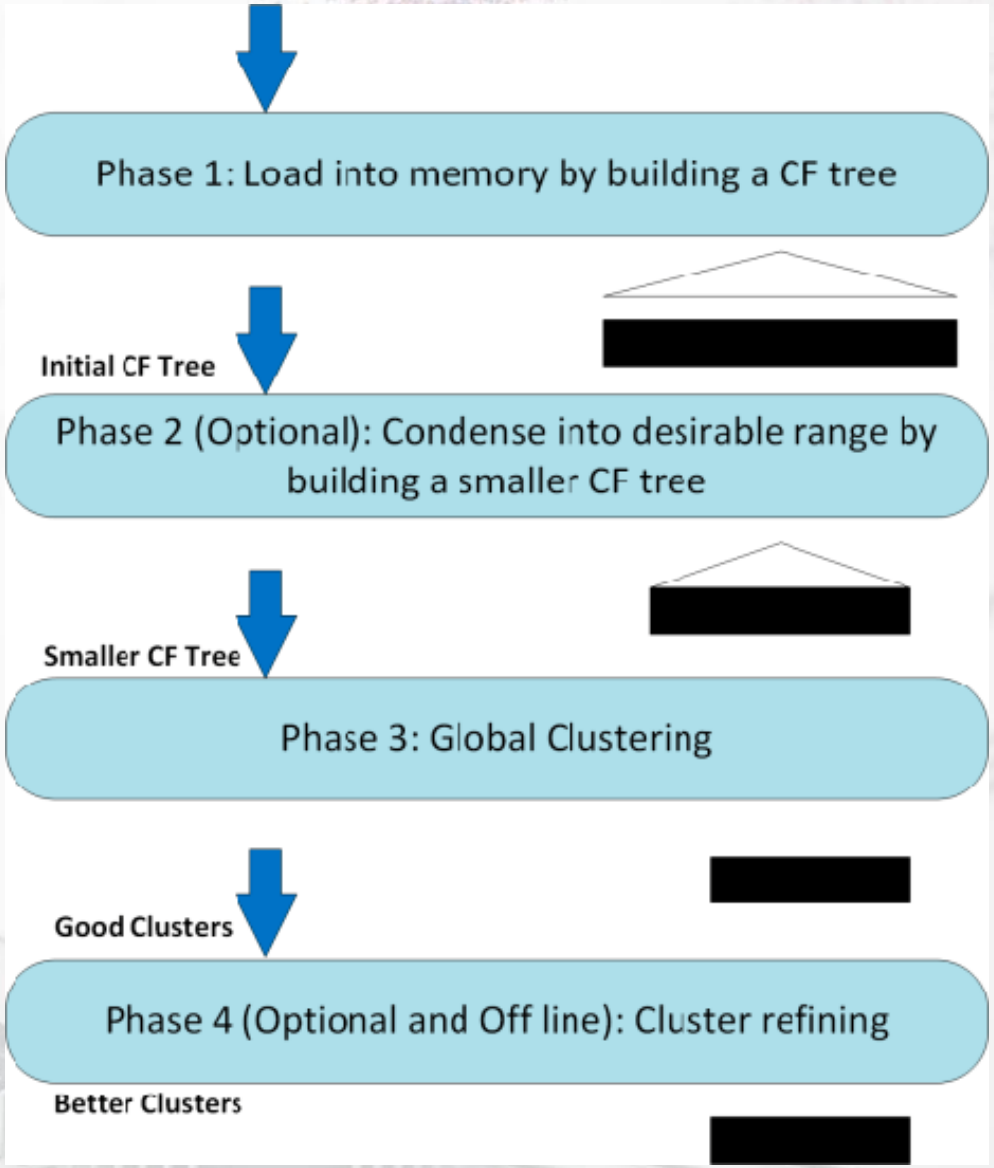
- Thuật toán quét cơ sở dữ liệu một lần, tạo CF cho mỗi điểm dữ liệu.
- Những CF này được chèn vào cây CF.

1. Xây dựng cây CF:

- Cây CF được xây dựng tăng dần khi các điểm dữ liệu được xử lý.
- Các CF mới được chèn vào cây và các CF hiện có sẽ được hợp nhất nếu chúng đủ gần.

1. Phân cụm:

- Khi cây CF được xây dựng, việc phân cụm có thể được thực hiện:
  - **Phân cụm toàn cục:** Cây CF được duyệt qua và các CF được hợp nhất hoặc phân tách để tạo thành các cụm.
  - **Phân cụm vi mô:** Các cụm nhỏ hơn có thể được tinh chỉnh thêm bằng cách sử dụng các thuật toán phân cụm khác như K-means hoặc DBSCAN.



Thuật toán BIRCH

Ưu điểm của BIRCH:

- Hiệu quả: Nó có thể xử lý các tập dữ liệu lớn một cách hiệu quả do tính chất gia tăng và việc sử dụng cây CF.

- Khả năng mở rộng: Nó có thể mở rộng quy mô thành các tập dữ liệu lớn bằng cách điều chỉnh các tham số như ngưỡng để hợp nhất các CF.

- Đơn giản: Tương đối dễ thực hiện và dễ hiểu. **- Tính linh hoạt:** Nó có thể được sử dụng như một bước tiền xử lý cho các thuật toán phân cụm khác hoặc như một thuật toán phân cụm độc lập.

Hạn chế của BIRCH:

- Độ nhạy đối với Cài đặt Tham số: Hiệu suất của BIRCH có thể nhạy cảm với các tham số như ngưỡng để hợp nhất các CF.

- Chất lượng phân cụm hạn chế: Trong một số trường hợp, BIRCH có thể không tạo ra kết quả phân cụm tối ưu, đặc biệt đối với các tập dữ liệu phức tạp.

Ví dụ về học tập scikit

→ **https://github.com/scikit-learn/scikit-learn/blob/main/sklearn/cluster/_birch.py**

Đo lường số liệu

Các thước đo đánh giá nội bộ

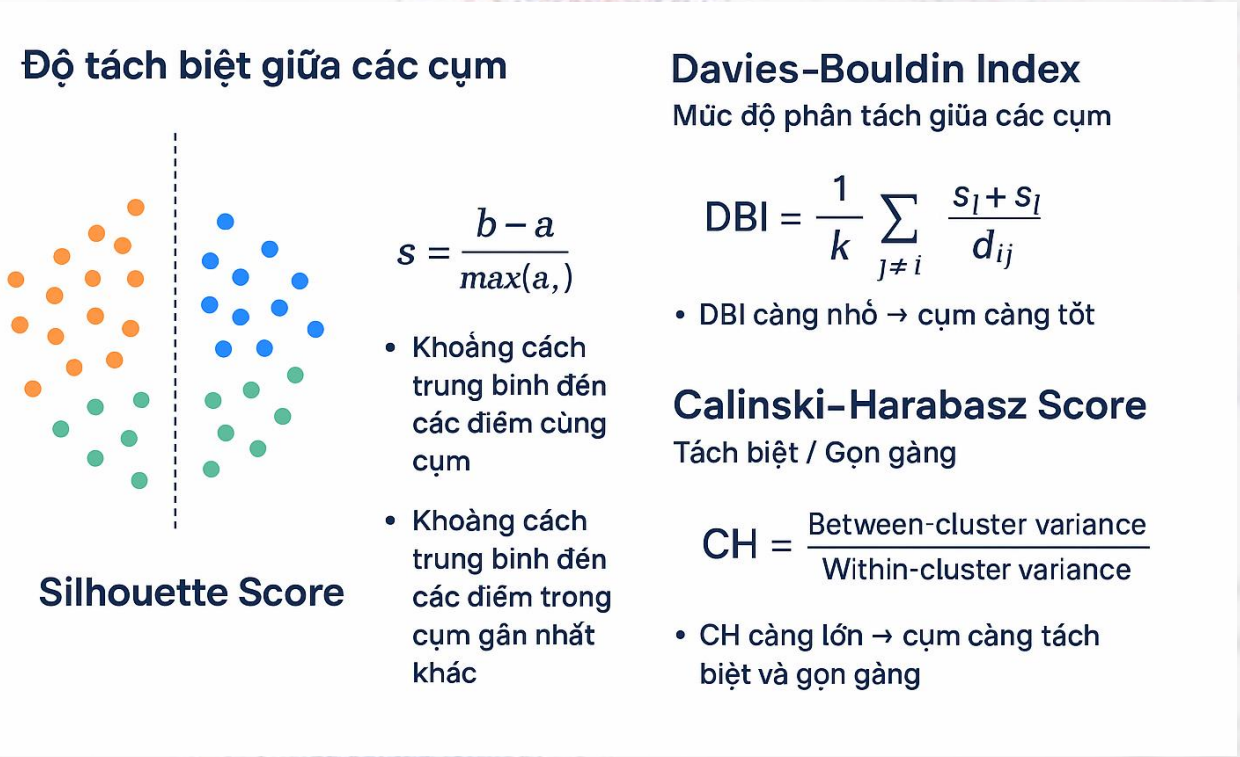
- **Hệ số hình bóng:** Đo mức độ tương tự của một điểm dữ liệu với cụm của chính nó so với các cụm khác. Hệ số cao hơn biểu thị các cụm được xác định tốt hơn.
- **Chỉ số Davies-Bouldin:** Đánh giá mức độ tương tự trung bình giữa mỗi cụm và cụm tương tự nhất của nó. Giá trị thấp hơn biểu thị các cụm được phân tách tốt hơn.
- **Chỉ số Calinski-Harabasz**:Đo tỷ lệ giữa tổng độ phân tán giữa các cụm và độ phân tán bên trong cụm. Giá trị cao hơn cho thấy các cụm được xác định rõ hơn.

Các thước đo đánh giá bên ngoài

- **Chỉ số Rand:** Đo lường mức độ tương tự giữa hai cụm. Chỉ số Rand cao hơn cho thấy sự đồng thuận tốt hơn giữa hai nhóm.
- **Chỉ số Rand được điều chỉnh:** Một biến thể của Chỉ số Rand được điều chỉnh theo thỏa thuận ngẫu nhiên.
- **Thông tin lẫn nhau được chuẩn hóa:** Đo lượng thông tin được chia sẻ giữa hai cụm. Giá trị cao hơn cho thấy thỏa thuận tốt hơn.

Chỉ số đánh giá cho bài toán Clustering

Chỉ số	Ý nghĩa
Silhouette Score	Đo **độ tách biệt và độ gọn** của các cụm. Giá trị càng gần **1** → cụm càng rõ ràng, tách biệt tốt.
Davies–Bouldin Index (DBI)	Đo mức độ **giống nhau giữa các cụm**. **DBI càng nhỏ → cụm càng tốt**, phân tách rõ hơn.
Calinski–Harabasz Score (CH Score)	Đo mức độ **tách biệt giữa các cụm so với độ gọn trong cụm**. **CH càng lớn → chất lượng phân cụm càng cao**.



Bài tập thực hành 3

Vấn đề: Bạn có tập dữ liệu chứa thông tin về khách hàng của một cửa hàng bán lẻ, bao gồm tuổi, giới tính, thu nhập hàng năm và điểm chi tiêu của họ. Nhiệm vụ của bạn là phân nhóm khách hàng dựa trên những điểm tương đồng của họ và xác định các phân khúc khách hàng riêng biệt.

Các bước:

1. Khám phá dữ liệu.

- Phân tích tập dữ liệu để tìm các giá trị còn thiếu, các ngoại lệ và phân phối các tính năng. - Trực quan hóa dữ liệu bằng cách sử dụng biểu đồ phân tán hoặc biểu đồ để xác định các mẫu.

2. Chia tỷ lệ tính năng. Bình thường hóa hoặc tiêu chuẩn hóa các đặc điểm (độ tuổi, thu nhập hàng năm và điểm chi tiêu) để đảm bảo chúng có quy mô tương tự.

3. Phân cụm.

- Chọn thuật toán phân cụm (ví dụ: K-means, K-medoids, DBSCAN, Hierarchical clustering,...). - Thử nghiệm với các thông số khác nhau và đánh giá kết quả bằng các số liệu thích hợp.

4. Đánh giá.

- Sử dụng các thước đo như hệ số bóng để đánh giá chất lượng của các cụm. - Trực quan hóa các cụm bằng cách sử dụng biểu đồ phân tán hoặc chương trình dendro để hiểu phân đoạn.

Bài tập thực hành 3 (bổ sung) Bài tập phân đoạn hình ảnh K-Means

Vấn đề: Phân đoạn một hình ảnh nhất định thành K cụm bằng thuật toán K-mean
Bộ dữ liệu: Bạn có thể sử dụng bất kỳ hình ảnh nào bạn chọn. Ví dụ: Hình ảnh tự nhiên như phong cảnh hoặc chân dung. **Nhiệm vụ:**

1. **Tải hình ảnh:**
   - Đọc hình ảnh bằng OpenCV hoặc PIL.
   - Chuyển đổi hình ảnh sang không gian màu phù hợp (ví dụ: RGB, HSV hoặc LAB).
2. **Xử lý trước hình ảnh:**
   - Thay đổi kích thước hình ảnh thành kích thước nhỏ hơn để xử lý nhanh hơn.
   - Làm phẳng hình ảnh thành một mảng pixel 2D, trong đó mỗi pixel được biểu diễn dưới dạng vectơ đặc trưng (ví dụ: giá trị RGB). 3. **Áp dụng phân cụm K-Means:**
   - Khởi tạo K trọng tâm ngẫu nhiên, mỗi trọng tâm đại diện cho màu trung bình của một cụm.
   - Gán từng pixel cho trọng tâm gần nhất dựa trên khoảng cách Euclide.
   - Cập nhật trọng tâm làm giá trị trung bình của các pixel được gán cho mỗi cụm.
   - Lặp lại các bước gán và cập nhật cho đến khi hội tụ.
4. **Phân đoạn hình ảnh:**
   - Thay thế mỗi pixel bằng màu của tâm cụm được chỉ định.
   - Định hình lại hình ảnh được phân đoạn trở lại kích thước ban đầu.
5. **Trực quan hóa kết quả:**
   - Hiển thị hình ảnh gốc và hình ảnh được phân đoạn cạnh nhau.

Ref:
https://medium.com/analytics-vidhya/image-segmentation-USE-k-means-clustering-from-scratch-1545c896e38e

Tài liệu tham khảo

https://www.kaggle.com/code/azminetoushikwasi/other-clustering-techniques-and-algorithms/notebook

https://github.com/scikit-learn/scikit-learn/tree/main/sklearn/cluster